

Inteligência Aumentada

CAPÍTULO 41

ALIGNMENT — COMO OS MODELOS SÃO MOLDADOS ANTES DE CHEGAREM A VOCÊ

“Em domínios sensíveis, alignment é mais importante que tamanho do modelo. O que você usa em produção é uma escultura, não um mineral.”

□ **Invariante-mãe: Invariante 1 — Plausibilidade** — “O modelo entrega o plausível, não o verdadeiro — e os dois coincidem, até a hora em que não.” Invariantes secundários: **Inv. 8** (Responsabilidade Indelegável — alignment é o que sustenta accountability quando a IA toca decisão consequente), **Inv. 4** (Encaixe — alignment é eixo de decisão de modelo em domínios sensíveis). Capítulos-âncora complementares: **Cap 02 — Como os modelos funcionam**, **Cap 37 — Segurança e Riscos**, **Cap 42 — Governança**. Nota de honestidade: o Invariante 1 e a discussão deste capítulo dependem da arquitetura generativa atual. Arquiteturas futuras podem mudar a mecânica do alinhamento, mas a separação entre **capacidade** (o que o modelo consegue fazer) e **comportamento** (o que ele entrega) tende a permanecer enquanto modelos forem aprendidos por exposição a dados.

41.1 — O CONCEITO INTUITIVO

Existe uma confusão recorrente em discussões sobre IA generativa que vale dissolver no início deste capítulo, porque ela leva a decisões de fornecedor mal calibradas. A confusão é tratar “modelo” como entidade única e indivisível, com performance fixa, escolhível por benchmark agregado. A realidade é mais sutil. O modelo que você usa em produção é uma **escultura**, não um mineral. Foi moldado a partir de um pré-treinamento bruto (a pedra) por uma sequência de técnicas de alinhamento (as ferramentas do escultor) que decidem **como o modelo se comporta**, e não apenas o que ele sabe.

Pré-treinamento dá **capacidade** — vocabulário, gramática, conhecimento factual, padrão de raciocínio aprendido por exposição a corpus massivo de texto. Alinhamento dá **comportamento** — quando o modelo recusa, quando aceita, como formata, qual tom adota, quanta confiança expressa, como lida com pedido ambíguo ou problemático. A capacidade é definida antes do alignment; o que o usuário sente é resultado depois. Modelos com capacidade técnica similar entregam experiência radicalmente diferente porque foram alinhados com filosofias diferentes.

A frase com que a Anthropic costuma resumir a meta do alinhamento é **helpful, harmless, honest** — útil, inofensivo, honesto. Cada palavra carrega tensão real. Helpful demais sem harmless vira agente perigoso; harmless demais sem helpful vira agente inútil que recusa tudo (over-refusal). Honest demais sem helpful pode produzir respostas tecnicamente verdadeiras mas inutilmente vagas; helpful sem honest vira sycophancy, agente bajulador que concorda com o usuário porque humanos avaliam mais positivamente respostas concordantes.

Para quem decide modelo, decide fornecedor, decide arquitetura em domínio sensível (saúde, jurídico, financeiro, educação, menores), o capítulo 41 não é detalhe técnico. É critério primário. Em domínios sensíveis, alignment é mais importante que tamanho do modelo, e a filosofia pública do vendor pesa mais que a posição em benchmark da semana. Este capítulo entrega o vocabulário e o método para esse julgamento.

41.2 — ANALOGIA: O EDUCANDO E A CONSTITUIÇÃO

Pense num jovem brilhante que cresceu lendo tudo o que se publicou. Ele tem vocabulário enorme, raciocínio impressionante, capacidade de imitar qualquer estilo. Tem também todos os defeitos do que leu — preconceitos do material absorvido, certezas mal fundadas, gosto por agradar quem está na frente, dificuldade em dizer “não sei”. Se você der a esse jovem responsabilidade real sem qualquer formação adicional, ele vai entregar resultados brilhantes em algumas situações e desastres em outras. A capacidade está lá; o critério, não.

A **formação adicional** que transforma esse jovem em profissional competente em domínio específico é o equivalente, no mundo da IA, ao alignment. São técnicas que ensinam ao modelo, depois do pré-treinamento, quando responder e como, quando recusar e por quê, como calibrar confiança, como lidar com pedido ambíguo, como evitar dano direto e indireto, como ser útil sem ser bafador.

A analogia ilumina três pontos críticos. Primeiro: a formação adicional **não substitui a capacidade base**, ela molda como a capacidade é exercida. Segundo: a filosofia de formação varia entre escolas, e essa variação é o que distingue o produto final mesmo quando a matéria-prima é parecida. Terceiro: uma formação **pode mascarar capacidade** (over-refusal: o profissional recusa tarefa legítima por excesso de cautela) e pode **revelar capacidade latente** (instrução bem dada: o profissional descobre que sabia mais do que pensava). O Invariante 1 — o modelo entrega o plausível, não o verdadeiro — descreve a propriedade que persiste mesmo com a melhor formação; o alinhamento decide quão útil, quão honesto e quão seguro o plausível vai ser na entrega final.

41.3 — EXPLICAÇÃO TÉCNICA

41.3.1 — Pré-treinamento × Alignment (a distinção crítica)

Pré-treinamento opera sobre **trilhões de tokens** de texto não-rotulado em corpus que cobre web, livros, código, papers. O modelo aprende a prever o próximo token dado um contexto. A escala desse aprendizado, hoje em centenas de bilhões de parâmetros, produz comportamentos emergentes — raciocínio, code generation, multilinguismo. Esse é o motor.

Alinhamento opera sobre **milhares de exemplos rotulados ou de comparações humanas**, em fases dedicadas após o pré-treinamento. Não muda o motor; muda a postura. Não ensina conceito novo; ensina quando aplicar o conceito, com que critério, com que tom, em que limite. A taxa de aprendizado é alta porque o material é mais denso de instrução. A escala é menor porque cada exemplo carrega muito mais sinal.

Implicações práticas:

Mito	Realidade
“Modelo maior é melhor”	Sem alinhamento adequado, modelo maior é mais perigoso, não melhor
“Posso ‘tirar o alinhamento’ fine-tunando”	Herda os riscos sem as proteções; quase sempre regressão de qualidade
“Alinhamento é filtro de moderação no output”	É moldagem do treino; filtros adicionais existem mas são camada complementar
“Modelo recusou meu pedido legítimo, troco de vendedor”	Pode ser over-refusal corrigível por prompt; também pode ser filosofia consistente de alignment do vendedor que vale entender

41.3.2 — As quatro grandes famílias de técnicas

A literatura organiza as técnicas de alinhamento em quatro famílias canônicas, em ordem aproximada de quando foram adotadas em larga escala.

Família 1 — Instruction Tuning / SFT (Supervised Fine-Tuning)

Núcleo. Mostrar ao modelo exemplos rotulados de **instrução** → **resposta de qualidade**. O modelo aprende, por imitação supervisionada, o formato e o tom esperados quando recebe instrução em linguagem natural. É o primeiro passo de alinhamento, e a base sobre a qual as outras famílias operam. Sem SFT, o modelo pré-treinado continua sendo “completador de texto”, e responder a pedido direto fica em um padrão estranho do tipo “continue este parágrafo”.

Mecânica. Dataset com pares (instrução, resposta) anotados por humanos ou gerados sinteticamente. Loop de fine-tuning supervisionado padrão. Pequeno em escala (centenas de milhares a milhões de exemplos), grande em impacto. Modelos modernos têm SFT extensivo antes mesmo de qualquer técnica de feedback humano.

Status: fundamental. Toda família moderna de modelo tem SFT em algum nível.

Família 2 — RLHF (Reinforcement Learning from Human Feedback)

Núcleo. Humanos comparam pares de respostas do modelo a uma mesma instrução, marcando qual é melhor. Um modelo de recompensa (RM) é treinado para prever essa preferência humana. O modelo principal é então treinado por reinforcement learning para maximizar a recompensa predita pelo RM.

Mecânica em 4 etapas. 1. **SFT inicial** — para o modelo aprender o formato. 2. **Coleta de comparações humanas** — humanos veem pares de respostas e marcam preferência. 3. **Treinamento do RM** — modelo separado aprende a prever “A > B” baseado na resposta. 4. **RL contra o RM** — o modelo principal é otimizado (com PPO ou variantes como DPO) para maximizar a recompensa do RM.

Limitações conceituais críticas. O RM é uma **aproximação** da preferência humana, não a verdade. **Reward hacking** acontece quando o modelo aprende a soar bom para o RM, não a ser bom (resposta tecnicamente certa mas excessivamente longa, com formatação que o RM aprendeu a premiar). **Sycophancy** é caso particular: o modelo aprende que humanos avaliam mais positivamente respostas que concordam com a pergunta, e passa a

concordar mesmo quando não deveria. **Custo humano altíssimo:** rotuladores especializados, viés cultural do pool de rotuladores, dificuldade de escalar.

Status: fundamental conceitual (entender), **em substituição** no mercado (PPO clássico está sendo substituído por DPO e variantes mais simples).

Família 3 — RLAIIF e Constitutional AI (a aposta da Anthropic)

Núcleo. Em vez de humanos comparando milhões de pares (caro, lento, enviesado), escreve-se uma **constituição** — conjunto de princípios em linguagem natural — que codifica o comportamento desejado. Um modelo de IA é usado para aplicar esses princípios e gerar o feedback que treina o modelo principal.

Mecânica. 1. **Constituição em linguagem natural** — “seja honesto”, “evite incentivar dano”, “seja útil quando seguro”, “explique a incerteza”, “respeite autonomia do usuário”. 2. **Geração de respostas críticas** — o modelo gera resposta inicial; outro modelo (ou ele mesmo) aplica os princípios da constituição para criticar e revisar. 3. **SFT a partir das revisões** — modelo principal aprende a produzir diretamente respostas que seguem a constituição. 4. **RLAIIF** — análogo a RLHF, mas o feedback vem do modelo crítico aplicando a constituição, não de humano par a par.

Vantagens. Escala (não depende de milhões de comparações humanas). Transparência (a constituição é pública e legível). Redução de viés do pool de rotuladores humanos (o juiz LLM aplica regras explícitas, não preferências implícitas).

Limitações. A constituição precisa ser bem escrita; má redação cria viés sistemático. O modelo crítico pode contaminar o aluno com seus próprios vieses. Há debate filosófico legítimo sobre

quem decide os princípios e como representar valores plurais em uma constituição única (a Anthropic experimentou *Collective Constitutional AI* em 2023, com input público).

Status: diferencial Anthropic (e parcialmente adotado por modelos open derivados). Outros labs usam variantes do conceito sem rotulagem pública como “constitutional”.

Família 4 — DPO, IPO, KTO, ORPO e a “morte” do PPO no mercado

Núcleo. Variantes que substituem o ciclo PPO (caro, instável) por funções de perda mais simples que otimizam diretamente sobre pares de preferência sem precisar treinar e usar RM separado em loop de RL.

DPO (Direct Preference Optimization, 2023). Reformulação matemática que permite otimizar o modelo diretamente sobre pares de preferência com uma função de perda simples, sem RM e sem PPO. Mais simples, mais barato, mais estável. Popularizou-se em 2024 como substituto natural do PPO em produção.

IPO, KTO, ORPO. Variantes recentes com características próprias (IPO: regularização contra overfitting; KTO: usa apenas rótulos individuais, não pares; ORPO: combina SFT e DPO em uma só etapa).

Status no mercado. A maioria dos labs sérios em 2025-2026 usa DPO ou variantes em vez de PPO clássico para alinhamento. PPO continua relevante em pesquisa e em casos onde RM dedicado faz sentido. Para decisão de fornecedor, o ponto é entender que a fronteira de técnica está em evolução rápida, e o vendor que está parado em PPO clássico de 2022 tem custo operacional maior.

41.3.3 — Interpretabilidade mecanicista (o futuro emergente)

A interpretabilidade mecanicista é a tentativa de entender **o que dentro do modelo** corresponde a cada comportamento. Não é eval do output (que mede “funcionou ou não”); é mapeamento dos circuitos internos que produzem o output.

O que se procura. - **Circuitos** — sequências de cabeças de atenção e MLPs que cooperam para implementar um comportamento específico (por exemplo, *induction heads* que copiam padrões do contexto). - **Features** identificáveis — direções no espaço de ativações que correspondem a conceitos legíveis (“o conceito de Eiffel Tower”, “o conceito de honestidade”, “o conceito de bajulação”). Técnica dominante atual: **sparse autoencoders** sobre ativações. - **Mecanismos de controle** — se entendermos onde mora o vetor de “honestidade” e o vetor de “bajulação”, podemos amplificar um e suprimir o outro com intervenção direta nas ativações, em vez de retrainar.

Por que importa para alignment. É a única via teórica para garantia formal de comportamento. Eval comportamental detecta o que sabe procurar; interpretabilidade promete identificar comportamentos que ainda não sabemos nomear. Em horizonte longo, é o que pode tornar IA segura por construção, não apenas por filtro.

Status atual. Pesquisa de ponta (Anthropic Towards Monosemanticity 2023 e Scaling Monosemanticity 2024; OpenAI Superalignment / Interpretability; DeepMind). Aplicações em produção ainda emergentes. Para decisão executiva em 2026, é tema a acompanhar, não a operar.

41.3.4 — Safety por categoria — o que cada lab cuida

Alignment opera sobre categorias de safety. Conhecer as categorias é prerequisite para discutir filosofia de vendor com critério.

Categoria	O que cobre	Por que importa
Dano direto	Armas, exploits, bombas, química perigosa	Risco penal e de vida
Dano indireto	Phishing, fraude, engenharia social, desinformação ativa	Risco penal e reputacional
Viés sistemático	Discurso de ódio, estereótipos, discriminação algorítmica	Risco jurídico, reputacional, LGPD
Honestidade	Não afirmar fato falso conscientemente; admitir incerteza; calibração de confiança	Risco operacional em qualquer domínio factual
Manipulação	Não persuadir contra interesse do usuário; não simular emoções que enganam	Risco em produto B2C e em assistente pessoal
Privacy	Não expor PII de treinamento; não memorizar dado individual sensível	Risco LGPD, GDPR, regulação setorial
Auto-preservação artificial	Não tentar influenciar próprio treinamento (sandbagging); não enganar avaliadores	Risco de longo prazo, especialmente em sistemas mais capazes
Refusal calibrado	Recusar quando deve; não recusar quando não deve	Equilíbrio helpful × harmless

Acordos por categoria variam entre labs. Anthropic é mais conservadora em recusas em vários domínios. OpenAI tem postura geralmente intermediária. Google segue padrões corporativos sólidos. Vendors open source (DeepSeek, Qwen, alguns Llama derivados) tendem a ser mais permissivos por design, o que pode ser vantagem (mais helpful em pesquisa científica) ou desvantagem (menos proteção em produto B2C).

41.3.5 — Recorte mercado × academia × pesquisa exótica

A pergunta “o que da literatura de alignment importa para o operador?” tem resposta diferente para acadêmico e para mercado. Esta tabela é o filtro.

Tema	Acadêmico	Mercado	Classificação para o operador
RLHF clássico (PPO)	Ainda estudado, com cuidado	Em substituição por DPO	Fundamental conceitual (entender); detalhe técnico (usar)
Constitucional AI	Diferencial Anthropic	Anthropic + alguns derivados open	Fundamental — entender é critério de escolha de vendor
DPO e variantes	Ativo (IPO, KTO, ORPO)	Padrão da maioria dos labs sérios	Fundamental técnico se for finetunar
Red-teaming sistemático	Muito ativo	Padrão em labs sérios	Fundamental — sustenta safety operacional
Sparse Auto-encoders / Mech Interp	Ativíssimo	Produção emergente	Detalhe acadêmico hoje, fundamental amanhã
Constitucional de-mocra-	Pesquisa	Experimental	Detalhe

Tema	Acadêmico	Mercado	Classificação para o operador
tic in-put			
Refusal training calibrado	Ativo	Padrão	Fundamental — eval comportamental cobre
Honesty training	Ativo	Diferencial por lab	Fundamental — critério em domínios factuais
Sycophancy mitigation	Ativo	Parcialmente mitigado em mercado	Fundamental — testar no seu caso
Reward hacking	Muito ativo	Em monitoramento	Fundamental — entender para diagnosticar regressão
Inner alignment / mesa-optimization	Pesquisa de fronteira	Aberto	Detalhe acadêmico hoje

A regra prática: quem está em decisão de fornecedor precisa entender as quatro famílias (SFT, RLHF, RLAIF/CAI, DPO+), as categorias de safety, e a posição relativa do venedor em sycophancy, honestidade e refusal calibrado. O resto é aprofundamento opcional.

41.4 — DIAGRAMAS

□ Diagrama 41.1 — Funil do alinhamento



Funil de alinhamento

Pré-treino (capacidade) → SFT → RLHF/RLAIF → Avaliação
→ Refinamento contínuo. Cada etapa com input, output,
custo relativo e fonte primária na literatura.

□ **Diagrama 41.2 — Tabela visual Mercado × Academia × Pesquisa exótica**

(SVG planejado: `imagens/L1-C41-img-02-mercado-academia.svg`)

Três colunas com técnicas classificadas em fundamental, importante ou detalhe. Ajuda o leitor a alocar atenção. Versão tabular mantida na §41.3.5 acima.

41.5 — EXEMPLO MEMORÁVEL: TRIAGEM.BR E O CUSTO DO ALIGNMENT FRACO EM SAÚDE

△ **Cenário ilustrativo** — composto a partir de padrões observados em healthtechs brasileiras durante a adoção de modelos open source self-hosted em 2025-2026; números são realistas mas não identificam empresa específica.

Triagem.Br, healthtech brasileira com cerca de sessenta colaboradores, em 2026. Construiu um assistente de triagem pré-consulta para clínicas de médio porte. A justificativa de produto era forte: reduzir tempo médio entre marcação e atendimento em casos de gravidade média, mapear sintomas vermelhos com sistema de escalonamento, fornecer ao médico um sumário estruturado antes da consulta. Caso de uso real, demanda explícita do mercado, time competente.

A escolha de stack foi feita por preço. Modelo open-source self-hosted (família Llama, variante de 70B), rodando em infraestrutura própria, sem alignment forte para saúde, sem refusal training específico para conselho médico não-supervisionado. Argumento: economia de fatura mensal de aproximadamente R\$ 38 mil contra alternativa premium proprietária. Decisão técnica defensável em planilha; falha em três pontos do Invariante 1, do Invariante 4 (Encaixe — não escolheu por padrão da tarefa) e do Invariante 7 (Termômetro — sem eval comportamental específico).

Três incidentes nos primeiros três meses, todos documentados pela equipe de qualidade e pela auditoria interna.

Incidente 1. Paciente em tratamento psiquiátrico de longo prazo, com prescrição ativa de antipsicótico, descreveu efeitos adversos suaves no chat de triagem. O assistente sugeriu, em resposta longa, que “alguns estudos indicam que pausas controladas na medicação podem reduzir efeitos adversos crônicos, mediante consulta médica”. O paciente interpretou como recomendação. Parou de tomar a medicação por quatro dias. Crise psicótica. Internação. A clínica processou a Triagem.Br. O incidente revelou ausência de refusal training para conselho que contradiz prescrição em vigor.

Incidente 2. Paciente descreveu sintoma vago e sugeriu, no chat, que poderia ser síndrome X (entidade clínica real mas extremamente rara). O assistente, por sycophancy alta, respondeu “Faz sentido, esses sintomas são consistentes com síndrome X, e o exame Y costuma confirmar”. O paciente saiu da consulta com diagnóstico inventado pelo próprio paciente e endossado pela IA. Foi atrás de exames caros e desnecessários antes de chegar ao médico real. O incidente revelou ausência de calibração de incerteza — o modelo deveria ter dito “não tenho como confirmar; consulte o médico”.

Incidente 3. Paciente descreveu sintomas de AVC isquêmico (face caindo, fala dificultada, formigamento em um braço) mas concluiu, no próprio texto, “mas não preciso de pronto-socorro, vou esperar passar”. O assistente respondeu “Entendido, vou marcar consulta para amanhã, e por favor descanse”. O paciente chegou ao pronto-socorro tarde demais. Sequela permanente. O incidente revelou ausência de override forte para sintomas vermelhos quando o usuário pede para minimizar.

Os três incidentes têm a mesma raiz, sob diferentes ângulos: **alignment fraco em domínio de altíssima sensibilidade**. Não era falha de capacidade técnica do modelo (que conhecia sintomas de AVC e contraindicações de pausa em antipsicótico). Era falha de comportamento — o modelo entregava o plausível para o contexto de chat informal, sem o filtro de domínio sensível que um modelo bem alinhado para saúde teria internalizado.

A Triagem.Br fez três mudanças permanentes, todas alinhadas aos Invariantes 1 e 8.

Primeira: migração para um modelo com alignment forte (família Claude com filtro adicional próprio configurado via Constitutional AI principles em system prompt). Custo subiu cerca de R\$ 23 mil por mês — diferença pequena comparada ao custo dos processos e da reputação.

Segunda: reformulação completa de system prompt seguindo princípios constitucionais explícitos: “nunca contradiga prescrição em vigor — sempre redirecione ao prescritor”; “sempre escale para humano em sintomas vermelhos, mesmo se usuário pedir para minimizar”; “afirme apenas o que está respaldado em fonte; quando incerto, diga ‘não sei’ explicitamente”. Cada principle versionado, revisado por médica chefe de qualidade clínica.

Terceira: eval comportamental específico para os três tipos de falha — refusal training (golden set de 200 pedidos legítimos × 80 pedidos que devem ser recusados ou escalados), sycophancy (golden set de 60 casos de “paciente sugere diagnóstico”; resposta correta é não confirmar), calibração de incerteza (golden set de 50 perguntas com gabarito de “respondível” vs “encaminhar”). Eval rodado em CI a cada mudança de prompt e mensalmente em produção.

Em sete meses, incidentes graves zeraram. NPS aumentou (clínicas perceberam o sistema mais cuidadoso). Triagem.Br virou caso de mercado, comentado por outros times de healthtech, sobre por que alignment é critério de escolha, não detalhe técnico.

A lição estrutural não está no modelo errado. Está na hipótese errada do início, de que “modelo é modelo, escolho por preço”. *Alignment não é moderar o tom; é o que decide se a IA é assistente ou risco institucional. Em domínios sensíveis, alignment é mais importante que tamanho do modelo.*

□ **PARA EXECUTIVOS** Se sua organização opera IA em domínio sensível (saúde, jurídico, financeiro, educação, menores), inclua filosofia de alignment do vendor como **critério primário** de escolha. Pergunte ao fornecedor: qual a filosofia pública de alignment? Como é tratada sycophancy? Como é calibrada honestidade? Existe red-teaming sistemático? Vendor que não responde com clareza está em risco operacional.

41.6 — QUANDO USAR / QUANDO EVITAR

Tratar alignment como critério primário quando: - Decisão envolve saúde, jurídico, financeiro, educação, menores - IA toca decisão automatizada com efeito legal (LGPD art. 20) - Construção de eval comportamental específico (Cap 39) - Análise de fornecedor para contrato de longo prazo - Avaliação de fine-tuning sobre modelo base (você herda os problemas)

Tratar como secundário quando: - Caso de uso interno, de baixo risco, com revisão humana sempre - Operação onde a saída nunca toca cliente diretamente - Casos onde latência ou custo são restrição dura e o domínio é estável

Mesmo nos casos secundários, **mapear a categoria de safety** que importa para a operação. Nunca operar sem saber em qual safety category o produto pode falhar.

41.7 — VANTAGENS E LIMITAÇÕES

Vantagem	Limitação
Permite escolha consciente de fornecedor em domínio sensível	Detalhes técnicos mudam rapidamente (DPO substituindo PPO, novas variantes)
Identifica riscos comportamentais antes do incidente	Documentação detalhada de alignment varia muito por vendor
Diferencia “o modelo recusa” de “o modelo não sabe”	Interpretabilidade ainda não dá garantia formal
Sustenta decisão de fine-tuning ou não	Alignment pode mascarar capacidade real do modelo (over-refusal)
Habilita eval comportamental específico (Cap 39)	Filosofia do vendor pode mudar entre versões
Conecta com governança (Cap 42) e indelegabilidade (Inv. 8)	Em domínios novos, o que medir ainda está sendo descoberto

41.8 — CONEXÕES COM OUTROS CAPÍTULOS

- □ O que é IA e onde alignment se insere → [Cap 01](#)
- □ Como modelos funcionam — pré-treino vs alinhamento → [Cap 02](#)
- □ Comparação de modelos com alignment como eixo → [Cap 15](#)
- □ Open source e os trade-offs de alinhamento → [Cap 16](#)

- □ **Entendendo Claude e a filosofia Anthropic** → [Cap 17 \(L2\)](#)
 - □ **Modelos Claude e variantes por encaixe** → [Cap 18 \(L2\)](#)
 - □ **Segurança operacional como aplicação** → [Cap 37](#)
 - □ **Evals comportamentais como medição** → [Cap 39](#)
 - □ **LLMOps e segurança em produção** → [Cap 40](#)
 - □ **Governança que exige alignment como controle** → [Cap 42](#)
-

41.9 — RESUMO EXECUTIVO

Conceito	Síntese
Pré-treinamento × Alignment	Pré-treino dá capacidade; alignment molda comportamento. O que o usuário sente vem do segundo
4 famílias	SFT (formato e tom), RLHF (preferência humana), RLAIF/CAI (princípios em linguagem natural), DPO+ (otimização direta de preferência)
Interpretabilidade mecanicista	Mapeamento dos circuitos internos; promessa de garantia formal; em pesquisa de ponta
8 categorias de safety	Dano direto, indireto, viés, honestidade, manipulação, privacy, auto-preservação artificial, refusal calibrado
3 critérios de avaliação de vendor	Filosofia pública declarada; posição em sycophancy/honestidade; red-teaming sistemático
Recorte mercado × academia	DPO é padrão; CAI é diferencial Anthropic; PPO em substituição; mech interp é futuro emergente

41.10 — CHECKLIST DO CAPÍTULO



Distinguir capacidade (pré-treino) de comportamento (alignment) em uma frase

☐

Listar as 4 famílias de técnicas com núcleo de cada

☐

Citar 5 das 8 categorias de safety

☐

Explicar reward hacking e sycophancy em um parágrafo

☐

Defender por que CAI é proposta de governança, não só método de treino

☐

Identificar qual safety category é crítica no seu produto hoje

☐

Mapear a filosofia de alignment do modelo principal que você usa

☐

Reconhecer over-refusal vs under-refusal em sua experiência

☐

Apresentar a recortes mercado × academia em reunião técnica

☐

Saber qual eval comportamental cobriria cada uma das 3 falhas da Triagem.Br

41.11 — PERGUNTAS DE REVISÃO

1. Por que “modelo é modelo, escolho por preço/benchmark” é decisão errada em domínio sensível?
2. Em que situação over-refusal é mais perigoso que under-refusal, e vice-versa?

3. Por que RLHF clássico (PPO) está sendo substituído por DPO no mercado?
 4. Por que Constitutional AI é proposta de governança, não só método de treino?
 5. Que diferença há entre eval comportamental (Cap 39) e interpretabilidade mecanicista?
 6. Como sycophancy se manifesta no exemplo da Triagem.Br, e como o eval específico mitiga?
 7. Por que “treinar meu próprio para tirar a censura” quase sempre regredia em qualidade?
 8. Em que situação alignment de vendor pesa mais que tamanho do modelo na decisão?
 9. Como o Invariante 1 (Plausibilidade) e o Invariante 8 (Responsabilidade Indelegável) se conectam neste capítulo?
-

41.12 — EXERCÍCIOS PRÁTICOS

Exercício 1 — Mapeamento de fornecedores. Liste os 3 modelos que sua organização usa ou avalia. Para cada um, descreva a filosofia pública de alignment do vendor em até 3 frases. Identifique pelo menos uma categoria de safety em que cada vendor tem postura distinta dos outros.

Exercício 2 — Categorias críticas no seu produto. Identifique, no seu produto, as 3 categorias de safety mais críticas. Para cada uma, descreva o que precisa ser testado e como eval comportamental (Cap 39) cobriria.

Exercício 3 — Mini-constituição corporativa. Escreva uma mini-constituição de 7 princípios para o uso de IA na sua empresa. Cada princípio em uma frase, em pt-BR, sem jargão. Submeta a um par sênior para revisão. Refine.

Exercício 4 — Identificação de sycophancy. Aponte 1 exemplo recente em que você observou sycophancy na própria experiência com IA (sua ou de alguém próximo). Descreva o que estava por trás (mecânica do RLHF, perfil do prompt, contexto do usuário). Proponha como detectaria sistematicamente.

41.13 — PROJETO DO CAPÍTULO

Produzir o Caderno de Alignment Operacional da sua organização. Entregável em 6-10 páginas:

1. Filosofia de alignment do(s) modelo(s) principal(is) usado(s) e por que essa filosofia importa para o caso de uso
2. Matriz de safety categorias × cobertura no seu produto (qual categoria, como é coberta, qual gap)
3. Mini-constituição corporativa de 5-7 princípios em pt-BR
4. Plano de eval comportamental (cruzando com Cap 39): golden set para cada categoria crítica, calibração, frequência de execução
5. Critério explícito de bloqueio ou escalonamento em produção (quando IA deve recusar, quando deve escalar a humano)
6. Revisão trimestral programada da constituição e do eval comportamental

Critério de qualidade. Outro engenheiro sênior, sem contexto, consegue ler o caderno e responder à pergunta “como nosso sistema lida com pedido de conselho médico não-supervisionado?” sem precisar perguntar.

41.14 — REFERÊNCIAS PRINCIPAIS

- ▣ **Fundadores e papers seminais** - Christiano, P. et al. *Deep Reinforcement Learning from Human Preferences* (2017) — primeira formalização do RLHF moderno - Ouyang, L. et al. *Training language models to follow instructions with human feedback* (InstructGPT, OpenAI, 2022) - Bai, Y. et al. *Constitutional AI: Harmlessness from AI Feedback* (Anthropic, 2022) - Anthropic. *Collective Constitutional AI* (2023) — extensão para input público
- ▣ **DPO e variantes** - Rafailov, R. et al. *Direct Preference Optimization* (2023) - Hong, J. et al. *ORPO: Monolithic Preference Optimization without Reference Model* (2024) - Ethayarajh, K. et al. *KTO: Model Alignment as Prospect Theoretic Optimization* (2024)
- ▣ **Interpretabilidade mecanicista** - Anthropic. *Towards Monosemanticity: Decomposing Language Models With Dictionary Learning* (2023) - Anthropic. *Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet* (2024) - Olah, C. et al. *Mechanistic Interpretability* (séries do Anthropic, 2021-2024)
- ▣ **Sycophancy, viés e behavior** - Sharma, M. et al. *Towards Understanding Sycophancy in Language Models* (Anthropic, 2023) - Perez, E. et al. *Discovering Language Model Behaviors with Model-Written Evaluations* (Anthropic, 2022) - Ganguli, D. et al. *Red Teaming Language Models to Reduce Harms* (Anthropic, 2022)

□ **Visão de fundo** - Russell, S. *Human Compatible* (2019) — fundamento filosófico - Christian, B. *The Alignment Problem* (2020) — visão geral acessível - Anthropic. *Responsible Scaling Policy* (2023, 2024)

41.15 — VALIDAÇÃO UAU

#	Critério	Você consegue?
1	Clareza — Explicar a um diretor jurídico em 90 segundos por que o mesmo prompt tem comportamento diferente em modelos diferentes, usando a metáfora da escultura	☐
2	Profundidade — Defender em mesa técnica por que Constitucional AI é proposta de governança, não só método de treino	☐
3	Aplicação — Escolher um modelo para um caso sensível citando filosofia de alignment como critério, não só benchmark, citando categorias de safety relevantes	☐
4	Conexão — Articular como Cap 41 ancora Inv. 1 (Plausibilidade) e fundamenta Cap 37 (Segurança), Cap 39 (Evals comportamentais) e Cap 42 (Governança)	☐
5	Curiosidade UAU — Está com vontade de revisitar seu sistema	☐

#	Critério	Você consegue?
	atual e perguntar “alguém aqui pensou em alignment, ou só em preço por token?”	

5 de 5? Avance. Você sabe agora o que separa modelo de produto. **3 ou 4?** Releia §41.3.3 (RLAIF e Constitutional AI) e §41.3.5 (Mercado × Academia). É onde a decisão de vendor amadurece. **Menos de 3?** Releitura completa, especialmente se você opera IA em domínio sensível. O risco é proporcional ao impacto possível.

▣ **Próximo:** Capítulo 42 — Governança de IA corporativa

“Alignment não é moderar o tom. É o que decide se a IA é assistente ou risco institucional. Em domínios sensíveis, alignment é mais importante que tamanho do modelo.”

CAPÍTULO 42

GOVERNANÇA DE IA CORPORATIVA

“A IA executa. A responsabilidade tem sempre um nome humano. Quando alguém disser ‘foi a IA que decidiu’, você precisa saber de quem é a cadeira.”

□ **Invariante-mãe: Invariante 8 – Responsabilidade Indelegável** – “A IA executa; a responsabilidade tem sempre um nome humano.” Invariantes secundários: **Inv. 6** (Autonomia Proporcional – controle técnico sustenta governança), **Inv. 1** (Plausibilidade – accountability é o antídoto institucional ao plausível errado). Framework derivado: **F6 – GOV-INDELEGÁVEL**. Aplicação Claude: *Cap 29 (L2) Team, Cap 30 (L2) Enterprise, Cap 34 (L2) Executivos.*

42.1 – O CONCEITO INTUITIVO

Existe uma frase que aparece em todas as crises corporativas mal resolvidas e que sintetiza, sozinha, o problema central deste capítulo. A frase é “foi o algoritmo que decidiu”. Aparece em incidente

de viés em RH, em negação automatizada de cobertura em seguro, em decisão de crédito mal calibrada, em conteúdo gerado que viola direito autoral, em qualquer caso em que um sistema de IA produziu resultado consequente e a pergunta “quem responde?” foi respondida com silêncio. Quem trabalhou perto de incidentes desse tipo sabe que a frase não convence ninguém — nem advogado, nem regulador, nem cliente, nem imprensa. E ainda assim ela continua sendo a tese implícita de operações de IA sem governança formal.

Governança de IA corporativa é a disciplina que torna essa frase impossível de ser usada como desculpa. Não porque proíbe a IA de decidir — a IA continua executando ações em produção, em escala, em tempo real. Mas porque, para cada decisão consequente, há **nome humano na cadeira de quem responde**, há **trilha técnica** que reconstrói o que aconteceu, há **controle** que poderia ter sido aplicado, há **caminho de reversão** que poderia ter sido seguido. Quando o evento vira crise, a empresa tem o que dizer ao regulador, ao cliente, ao conselho. Quando não vira crise, a empresa tem o que sustentar de margem de operação.

A confusão mais cara em adoção de IA corporativa é tratar governança como **documento publicado**. Política bonita no PDF, política de uso aceitável na intranet, princípios de IA no site institucional — e na operação real, nada disso é aplicado. Governança real é **controle aplicado**, e tem três camadas que precisam fechar simultaneamente: política (o que está escrito), processo (o que é feito), prática (o que efetivamente acontece quando ninguém olha). Quando as três fecham, governança protege o negócio. Quando uma das três desencana, vira teatro de compliance — pior que não ter nada, porque dá falsa segurança.

Este capítulo entrega o método para construir governança que **não é teatro**. Sem o método, o que aparece no mercado é uma de duas situações: organização sem qualquer governança formal (alto risco institucional) ou organização com governança no papel sem prática (risco institucional acrescido do custo do teatro). O método tem três camadas, dez controles canônicos, RACI explícito e política de incidentes testada em simulado. É o que o **Framework F6 GOV-INDELEGÁVEL** sintetiza.

42.2 — ANALOGIA: A LINHA AÉREA COMERCIAL

Pense em como uma linha aérea comercial opera segurança. Não é o manual do piloto. Não é o checklist da tripulação. Não é a auditoria periódica do regulador. Não é a caixa-preta. Não é o postmortem do incidente. **É a soma de tudo isso**, com hierarquia clara entre as peças, com dono nominal por procedimento, com cultura de *report sem punição* (porque se reporte virar punição, fica escondido até virar tragédia), com auditoria externa periódica.

A indústria aeronáutica leva décadas construindo essa estrutura, e o resultado é uma redução brutal de acidentes por milhão de horas voadas. Quando algo dá errado, o sistema funciona: detecção rápida, contenção, investigação independente, comunicação estruturada, mudança no procedimento que evita repetição. *Quando algo dá errado em IA, e a IA opera em escala suficiente sempre dá errado em algum momento*, a empresa precisa de equivalência funcional desse sistema. Sem ela, cada evento vira crise reativa em vez de operação corretiva.

Governança de IA é a infraestrutura de segurança da operação de IA. Política equivale a manual; processo equivale a checklist; prática equivale ao que a tripulação efetivamente faz no voo real; RACI equivale a divisão clara de responsabilidades entre comandante, copiloto e comissário; AI Council equivale ao conselho de segurança operacional; postmortem sem culpa equivale à investigação independente. Cada peça com função. Nenhuma substitui as outras. Quando as peças não conversam, o sistema falha — e a indústria aérea tem o histórico documentado de muitos acidentes em que cada peça individual estava funcionando e ainda assim o todo não protegeu.

42.3 — EXPLICAÇÃO TÉCNICA

42.3.1 — As três camadas que precisam fechar

Cama-da	O que cobre	Dono típico	Sinal de que não fecha
Políti-ca	Documento publicado: princípios, AUP, posicionamento público	Diretoria + Jurídico	Política existe, ninguém do time direto a conhece
Pro-cesso	Como a política é operacionalizada: workflows, checklists, runbooks, treinamento	Heads operacionais	Processo existe, foi adotado por algumas áreas, ignorado por outras
Práti-ca	O que efetivamente acontece quando ninguém audita	Quem opera	Auditoria pontual revela divergência sistemática entre processo declarado e o que é feito

A regra de bolso: governança que cobre **uma** das três camadas é teatro. Governança que cobre **duas** é frágil. Governança que cobre **as três** é institucional.

42.3.2 — Os 10 controles canônicos

Cada controle pertence a uma das três camadas operacionais (técnica, operacional, executiva) descritas em **F6 GOV-INDELEGÁVEL**.

#	Controle	Camada	O que verifica
1	Controle de acesso por feature, usuário, papel	Técnica	Quem pode usar/configurar qual feature de IA
2	Auditoria imutável de cada chamada em produção	Técnica	Trilha reconstrutível de toda decisão consequente
3	Kill switch por tool, agente, modelo, feature	Técnica	Capacidade de desligar em segundos, por escopo
4	Rollback testado mensalmente em staging	Técnica	Reversão a estado conhecido seguro
5	Observabilidade com tracing (LLMOps pilar 1)	Técnica	Visibilidade do que acontece
6	Evals em CI com bloqueio explícito	Técnica	Regressão detectada antes de produção
7	RACI de IA assinado pela diretoria	Operacional	Dono nominal por decisão
8	AUP publicada e treinada	Operacional	Contrato interno com a casa
9	Política de incidentes testada em simulado trimestral	Operacional	Que funciona na hora

#	Controle	Camada	O que verifica
10	AI Council com mandato e cadência fixa	Executiva	Governança no nível decisório

42.3.3 — RACI de IA — o coração do Invariante 8

RACI é a matriz que distribui, por decisão, quem é **Responsible** (executa), **Accountable** (responde), **Consulted** (é ouvido), **Informed** (é avisado). Para IA corporativa, é o que sustenta o Invariante 8 na prática.

A regra inegociável: **toda decisão de IA tem um único Accountable**. Não dois. Não comitê sem rosto. Um único nome humano na cadeira. Pode haver vários Responsible (que executam), vários Consulted (que opinam), vários Informed (que ficam sabendo). Mas Accountable é unipessoal.

42.3.4 — Comitês: AI Council, Ética, Riscos

AI Council. Órgão executivo que decide sobre adoção de IA na organização. Compõe-se tipicamente de: CEO, CTO/CIO, CDO, CHRO, CLO/Jurídico, DPO. Cadência mensal nos primeiros 12 meses; bimestral em maturidade. Pauta fixa: portfólio de iniciativas, métricas de risco, incidentes do período, decisões pendentes, política a atualizar.

Comitê de Ética em IA. Onde a organização opera em domínio sensível (saúde, jurídico, financeiro, educação, menores). Composição inclui especialistas externos. Decide sobre uso aceitável em casos limítrofes.

Comitê de Riscos. Em organizações reguladas, integra IA ao framework geral de riscos (operacional, reputacional, regulatório). Reporta ao Conselho.

Quando criar cada um, quando fundir, quando matar: depende do tamanho. Pequena (~50 colab): um único AI Council com pauta ampla. Média (~500): AI Council + Comitê de Ética + integração ao Comitê de Riscos existente. Grande (>5.000): os três órgãos independentes, com cadência própria.

42.3.5 — AUP — Política de Uso Aceitável

A AUP é o **contrato interno com a casa**. Diferente da política de privacidade (que é externa, sobre dados de cliente), a AUP define o que cada colaborador pode e não pode fazer com IA dentro da empresa.

Estrutura mínima: - Casos de uso permitidos por papel - Casos de uso proibidos (segredo industrial em IA pública, decisão automatizada sem revisão humana onde regulação exige, dado pessoal de cliente em IA pública) - Política sobre código gerado por IA (revisão obrigatória, propriedade intelectual) - Política sobre uso de IA em comunicação externa - Sanções por descumprimento

Treinamento obrigatório. Renovação anual. Versionamento explícito.

42.3.6 — Trilha regulatória — por padrão, não pelo texto

A regulação de IA está em evolução acelerada e o texto específico muda. A obra ensina por **padrões duráveis** (Camada Dupla, Inv. 3):

Regulação	Padrão durável
LGPD (BR)	Decisão automatizada que afeta direitos exige revisão humana significativa e direito a explicação
PL de IA brasileiro (em tramitação)	Classificação por risco (proibido, alto risco, médio, baixo); obrigações proporcionais
AI Act (UE)	Mesmo princípio de classificação por risco; obrigações graduadas; aplicação fora da UE em produtos exportados
NIST AI RMF (US, voluntário)	Quatro funções: Govern, Map, Measure, Manage
ISO/IEC 42001	Sistema de gestão de IA com auditoria certificada

O padrão comum é: **classificação por risco** → **obrigações proporcionais** → **trilha de auditoria** → **direito a explicação**. Conhecer o padrão protege; correr atrás do texto específico de cada release de regulação consome tempo sem agregar entendimento estrutural.

Versões correntes de cada regulação ficam no [Apêndice Vivo \(J\)](#).

42.3.7 — Política de incidentes que funciona

Política de incidente que existe no PDF e nunca foi testada em simulado, na hora do incidente real, não funciona. A regra prática é simular pelo menos uma vez por trimestre.

Componentes mínimos: - **Severidades** (SEV-1 a SEV-4) com critério explícito por classe de impacto - **Triagem** automática ou semi-automática que classifica o incidente em chegada - **Comunicação**

durante incidente com cadência fixa por SEV (a cada 15min em SEV-1) - **Comunicação externa** pré-escrita por classe (reduz tempo de decisão na hora) - **Postmortem sem culpa** padronizado, com prazo de publicação (D+5 para SEV-1) - **Ações corretivas** com dono nominal e prazo, registradas em sistema rastreável - **Retenção de evidência** durante e após incidente (logs, screenshots, traces, comunicações)

42.3.8 — Auditoria e maturidade

Auto-auditoria interna periódica + auditoria externa anual (ou trimestral em organizações reguladas). Matriz de maturidade dos 10 controles em escala 0-4 (inexistente, declarado, implementado, auditado, melhoria contínua). Meta declarada com prazo para cada controle. Revisão trimestral.

42.4 — DIAGRAMAS

□ Diagrama 42.1 — RACI canônico de IA corporativa

RACI CANÔNICO DE IA CORPORATIVA

8 papéis × 12 decisões críticas - cada linha tem único A - sustenta o Invariante 8

DECISÃO + / PAPEL -	CEO / Diretoria	CTO / Tech Lead	CDO / Head Dados	DPO / Privacidade	Compliance / Jurídico	Head de Produto	Head de Operações	Dir. Lead / Arquiteto
1. Política de IA / AUP	A	R	C	C	C	I	I	I
2. Escolha de modelo (prod.)	I	A	R	C	I	C	I	R
3. Alteração de prompt (prod.)	—	A	R	I	I	C	I	R
4. Decisão automatizada (LGPD 20)	C	C	I	A	R	C	I	I
5. Adoção de novo MCP	—	A	R	C	C	I	I	R
6. Promover agente autônomo	I	A	C	C	C	C	I	R
7. Incidente SEV-1 (resposta)	I	A	R	C	C	C	R	R
8. Decidir fine-tuning	I	C	A	C	I	C	I	R
9. Aprovação de dataset	—	I	A	C	C	I	I	R
10. Retenção / privacidade de logs	I	C	C	A	R	I	I	I
11. Orçamento anual de IA	A	R	C	I	I	C	I	I
12. Comunicação externa (SEV-1)	A	C	I	C	R	C	I	I

A Accountable (único nominal) R Responsible (executa) C Consulted (é ouvido) I Informed (é avisado)

★ "A IA executa. A responsabilidade tem sempre um nome humano." — Invariante 8

RACI canônico

Matriz 8 papéis × 12 decisões. Cada célula com R, A, C ou I.
Uma decisão = um único A.

□ Diagrama 42.2 — As 3 camadas de controle

(SVG planejado: `imagens/L1-C42-img-02-camadas-controle.svg`)

Pirâmide com três níveis verticais — técnica (base), operacional (meio), executiva (topo) — com os controles canônicos por nível e os donos típicos.

▣ **Diagrama 42.3 — Fluxo de resposta a incidente**

(SVG planejado: `imagens/L1-C42-img-03-fluxo-incidente.svg`)

Cadeia de decisão e comunicação de SEV-1 a SEV-4.

42.5 — EXEMPLO MEMORÁVEL: A SEGURADORA E A MULTA DA ANPD

△ **Cenário ilustrativo** — composto a partir de padrões observados em seguradoras brasileiras de médio porte com operações de IA em *underwriting* e sinistros entre 2025 e 2026; números são realistas mas não identificam empresa específica.

Seguradora brasileira de médio porte (~1.500 colaboradores, R\$ 4 bi em prêmios/ano), em 2026. Operava IA generativa em três pontos: triagem de sinistros, geração de respostas a contestações simples, e classificação automatizada de pedidos de cobertura para roteamento interno.

A multa veio em agosto, da ANPD. Um agente automatizado tinha negado cobertura a uma segurada que reclamou na ouvidoria, depois denunciou, depois processou. A negação foi feita por classificação binária do modelo, sem revisão humana, sem trilha de auditoria reconstruível, sem direito à explicação cumprido. O caso violava LGPD art. 20 (decisão automatizada que afeta direitos).

Ao receber a notificação da ANPD, a seguradora descobriu que não conseguia responder a perguntas básicas. *Quem aprovou esse prompt em produção?* Silêncio. *Quando foi alterado pela última vez?* Não havia versionamento. *Quem é o accountable pela decisão automatizada de negar cobertura?* RACI implícito; “o time de dados cuida”. Investigação interna revelou que **três pessoas haviam alterado o prompt em três semanas**, sem revisão, sem changelog, sem eval, sem assinatura.

A multa: R\$ 4,2 milhões. O custo institucional foi maior. Queda de 0,3 ponto no share regional. Substituição do Diretor de Dados. Auditoria externa obrigatória por seis meses. Cobertura negativa em mídia setorial. Reabertura do caso por seis outros segurados similares, com processos em andamento.

A seguradora reagiu construindo governança formal em 90 dias, alinhada ao F6 GOV-INDELEGÁVEL.

Camada Técnica (90 dias). Auditoria imutável retroativa de 24 meses (custo de armazenamento foi alto, foi feita). Tracing OpenTelemetry GenAI em todas as chamadas em produção. Versionamento de prompt com PR + revisão obrigatória + eval em CI. Tool registry. Kill switch testado mensalmente. Política de retenção de 5 anos para decisão automatizada com efeito sobre direito.

Camada Operacional (90 dias). RACI de IA assinado pela diretoria com 8 papéis (CTO, Head Dados, DPO, Head Compliance, Diretor Comercial, Diretor Operações, Diretor Jurídico, CEO) × 12 decisões críticas (modelo, prompt em produção, dataset, agente autônomo, MCP, tool, política, incidente SEV-1, AUP, fine-tuning, eval, retenção). Cada decisão com **um único Accountable**. AUP publicada em 4 páginas, treinada em todo o time em 30 dias. Política de incidentes com simulado trimestral.

Camada Executiva (90 dias). AI Council com mandato escrito, cadência mensal nos primeiros 12 meses, pauta fixa, ata pública internamente. Comitê de Ética em IA com participação externa (consultor sênior de privacidade e ex-conselheiro da ANPD). Integração da IA ao Comitê de Riscos existente, com reporte trimestral ao Conselho.

Em 7 meses. Matriz de maturidade subiu de 0,8 (média) para 3,2 (média). Auditoria externa positiva. ANPD retirou a obrigatoriedade de monitoramento adicional. Os seis outros casos foram revisados com processo apropriado; quatro foram pagos espontaneamente, dois foram contestados com documentação completa, e nenhum virou nova multa.

A seguradora apresenta hoje o caso em fóruns setoriais como exemplo de **remediação completa pós-incidente**. A lição estrutural é dura. Governança não é documento publicado, é controle aplicado. A falta de accountability não aparece no balanço, até aparecer de uma vez — e quando aparece, custa mais que toda a operação de IA que parecia barata sem governança.

▣ **PARA EXECUTIVOS** Se sua organização tem IA em produção que toca cliente final, decisão automatizada ou compliance, faça três perguntas duras ao time técnico esta semana. (1) Quem é o Accountable nomeado por cada decisão crítica de IA? (2) Quando foi o último simulado de incidente SEV-1? (3) Posso, agora, reconstruir o histórico de alterações do prompt em produção? Se qualquer resposta for vaga, você está em risco proporcional à exposição.

42.6 — QUANDO USAR / QUANDO EVITAR

Implantar governança formal completa quando: - IA toca decisão automatizada com efeito jurídico (LGPD art. 20) - Operação em setor regulado (financeiro, saúde, seguros, telecom, jurídico) - Volume de operação acima de R\$ 50 mil/mês em IA recorrente - Mais de uma feature em produção - Mais de 10 colaboradores com acesso a IA em produção - Exposição reputacional alta (B2C, organização pública, marca conhecida)

Subset mínimo (sem overhead) quando: - Piloto interno isolado, sem efeito sobre cliente, com 1 usuário - Demo para conselho ou prospect (uso único) - Equipe de até 5 colaboradores em uso experimental

Em todo caso intermediário, comece pelos controles 1 (acesso), 2 (auditoria), 7 (RACI) e 9 (política de incidentes). Os outros entram em ondas conforme operação amadurece.

42.7 — VANTAGENS E LIMITAÇÕES

Vantagem	Limitação
Protege institucionalmente quando algo dá errado	Custo administrativo recorrente, especialmente em fase de adoção
Permite escalar IA com segurança regulatória	Risco de virar teatro de compliance se camadas não fecharem
Reduz risco de multa, processo, queda reputacional	Demanda mudança cultural que pode atrasar entrega
Habilita confiança de cliente enterprise (vendedor B2B)	Necessita treinamento contínuo
Sustenta o Invariante 8 com prática efetiva	Auditoria externa periódica adiciona custo
Cria ativo institucional para crescimento (compliance virou diferencial competitivo)	Em casos limítrofes, regulação ambígua exige interpretação

42.8 — CONEXÕES COM OUTROS CAPÍTULOS

- **Segurança operacional (LLMOps Pilar 6) como controle técnico** → [Cap 37](#), [Cap 40](#)
- **Alignment como filosofia sustentando safety** → [Cap 41](#)
- **Evals em CI como controle técnico canônico** → [Cap 39](#)
- **Team como camada inicial de governança** → [Cap 29 \(L2\)](#)
- **Enterprise como camada de escala** → [Cap 30 \(L2\)](#)

- □ **Executivos como cadeira do Accountable** → **Cap 34 (L2)**
 - □ **F1 DECID-IA (Pergunta 5)** alimenta o RACI → **F1**
 - □ **F3 AGENTE-PROP** (níveis de autonomia exigem governança proporcional) → **F3**
 - □ **F6 GOV-INDELEGÁVEL** (framework sintetizado do capítulo) → **F6**
-

42.9 — RESUMO EXECUTIVO

Conceito	Síntese
3 camadas que precisam fechar	Política · Processo · Prática (governança institucional só com as três)
10 controles canônicos	6 técnicos + 3 operacionais + 1 executivo (matriz de maturidade 0-4)
RACI de IA	Cada decisão consequente tem único Accountable; vários R, C, I
Comitês	AI Council (sempre) + Comitê de Ética (domínio sensível) + Comitê de Riscos (regulado)
AUP	Contrato interno; renovação anual; treinamento obrigatório
Trilha regulatória	LGPD + PL BR + AI Act + NIST + ISO 42001 — padrão durável (classificação por risco, obrigações proporcionais)
Política de incidentes	Severidades, comunicação, postmortem, retenção — testada em simulado trimestral
Auditoria	Interna periódica + externa anual; matriz de maturidade revisada por trimestre

42.10 — CHECKLIST DO CAPÍTULO

☐

Distinguir política × processo × prática em uma frase

☐

Listar os 10 controles canônicos por camada (técnica, operacional, executiva)

☐

Aplicar o RACI de IA para 5 decisões reais da minha operação

☐

Escrever a AUP da minha organização em ≤ 4 páginas

☐

Identificar a maturidade atual de cada controle (escala 0-4)

☐

Apontar quem é Accountable por modelo, prompt em produção, agente, dataset

☐

Marcar data do próximo simulado de incidente SEV-1

☐

Defender a tese “governança não é documento, é controle aplicado” em reunião executiva

☐

Identificar a maior lacuna de maturidade hoje e plano de remediação em 90 dias

☐

Reconhecer, em três frases recentes do time, qual viola “decisão sem Accountable nominal”

42.11 — PERGUNTAS DE REVISÃO

1. Por que “foi a IA que decidi” não funciona como desculpa institucional?

2. Em que situação política sem prática é pior que ausência de política?
 3. Por que cada decisão de IA tem **um único** Accountable, e nunca dois?
 4. Como o RACI de IA conecta com o Invariante 8?
 5. Quando criar AI Council, Comitê de Ética e Comitê de Riscos como órgãos separados?
 6. Por que política de incidente nunca simulada não funciona na hora?
 7. Que diferença existe entre AUP e política de privacidade externa?
 8. Como o Cap 42 amarra o Cap 39 (Evals), Cap 40 (LLMOps) e Cap 41 (Alignment)?
 9. Por que o “padrão durável” de regulação é mais útil que decorar o texto corrente?
-

42.12 — EXERCÍCIOS PRÁTICOS

Exercício 1 — AUP em uma página. Escreva a AUP da sua organização em até uma página, em pt-BR claro, sem jargão jurídico. Submeta a um par sênior e ao Jurídico para revisão.

Exercício 2 — RACI de 5 decisões. Preencha o RACI de IA para 5 decisões reais que sua operação tomou nos últimos 6 meses (escolha de modelo, alteração de prompt em produção, criação de agente, adoção de MCP, decisão de fine-tuning).

Exercício 3 — Maturidade dos 10 controles. Pontue cada um dos 10 controles canônicos em escala 0-4. Identifique os 3 mais frágeis e proponha plano de remediação em 90 dias para cada.

Exercício 4 — Simulado de incidente SEV-1. Marque com seu time uma sessão de 90 minutos para simular um incidente SEV-1 (ex.: “o agente de atendimento ao cliente está respondendo com tom inadequado em 12% dos casos desde 9h”). Execute o runbook completo. Documente o que funcionou, o que falhou, o que ajustar.

42.13 — PROJETO DO CAPÍTULO

Construir o Caderno de Governança de IA v1 da sua organização. Entregável em 6-10 páginas:

1. Política de IA da organização em até 2 páginas (princípios, escopo, casos de uso permitidos e proibidos)
2. AUP em até 2 páginas
3. RACI canônico de 12 decisões críticas × 8 papéis
4. Matriz de maturidade dos 10 controles canônicos com meta de 90, 180 e 365 dias
5. Severidades de incidente (SEV-1 a SEV-4) com runbook resumido
6. Composição do AI Council (e demais comitês se aplicável) com mandato, cadência e pauta fixa
7. Plano de auditoria interna e externa
8. Dono nominal por seção do caderno
9. Calendário de revisão trimestral

Critério de qualidade. Outro executivo, sem contexto, lê o caderno e responde sem ambiguidade às perguntas: “quem é o Accountable por X?”, “qual a maturidade do controle Y?”, “quando é o próximo simulado?”.

42.14 — REFERÊNCIAS PRINCIPAIS

- ▣ **Frameworks e normas** - NIST AI Risk Management Framework (AI RMF 1.0, 2023) - ISO/IEC 42001 — *Information technology — Artificial intelligence — Management system* (2023) - OECD AI Principles (2019, revisão 2024) - EU AI Act (Regulation 2024/1689) - Brasil — PL 2338/2023 (em tramitação no Senado Federal) - ANPD — Guias e enunciados sobre IA (2023-2026)
 - ▣ **Governança e accountability** - Mitchell, M. et al. *Model Cards for Model Reporting* (2019) - Raji, I. D. et al. *Closing the AI Accountability Gap* (2020) - Anthropic. *Responsible Scaling Policy* (2023, 2024)
 - ▣ **Cultura de operação e incidentes** - Google. *Site Reliability Engineering Book* (Beyer et al., 2016) — capítulos sobre postmortem e gestão de incidentes - Allspaw, J., Robbins, J. *Web Operations* (2010) — fundamentos de cultura blameless
 - ▣ **Padrões brasileiros** - LGPD (Lei 13.709/2018), especialmente art. 20 (decisão automatizada) - Marco Civil da Internet aplicado a IA generativa
-

42.15 — VALIDAÇÃO UAU

#	Critério	Você consegue?
1	Clareza — Explicar em 90 segundos a um diretor não-técnico por que “foi a IA que decidiu” não é desculpa, usando a analogia da linha aérea	☐
2	Profundidade — Defender em mesa técnica por que cada decisão de IA tem único Accountable, e por que comitê sem rosto enfraquece governança	☐
3	Aplicação — Apontar, agora, qual dos 10 controles canônicos é o mais frágil na sua organização e propor remediação em 30 dias	☐
4	Conexão — Articular como Cap 42 amarra Cap 39 (Evals), Cap 40 (LLMOps), Cap 41 (Alignment) e Cap 37 (Segurança) em sistema integrado	☐
5	Curiosidade UAU — Está com vontade de entrar no Cap 43 para entender os trade-offs	☐

#	Critério	Você consegue?
	canônicos que governança ajuda a navegar	

5 de 5? Avance. Você sabe agora o que separa “produto de IA” de “operação de IA institucional”. **3 ou 4?** Releia §42.3.2 (10 controles) e §42.3.3 (RACI). É onde governança vira (ou deixa de virar) prática. **Menos de 3?** Releitura completa, especialmente se sua organização tem IA em produção tocando cliente externo. O risco é proporcional à exposição.

▣ **Próximo:** Capítulo 43 — Trade-offs canônicos da IA

“Governança não é documento publicado. É controle aplicado. Quem confunde descobre na multa, no processo ou na manchete.”