

Inteligência Aumentada

FRAMEWORK F1 — DECID-IA

Decisão de adoção de IA por iniciativa

□ **Invariante-mãe: Invariante 9 — Operador** — “A IA multiplica competência e incompetência pelo mesmo fator.” Invariante secundário: **Inv. 8 — Responsabilidade Indelegável** (toda iniciativa tem cadeira humana). Capítulo-âncora: **Cap 34 (L2) — Claude para Executivos + Cap 44 — Roadmap pessoal e organizacional**.

1. OBJETIVO

Decidir, em até 30 minutos, se uma iniciativa específica deve usar IA, com qual nível de autonomia, e quem é o dono. Sai com cinco respostas duras e um plano mínimo, ou sai com a recusa documentada da iniciativa por critério explícito.

2. FUNCIONAMENTO

Cinco perguntas em ordem rígida. Sair em qualquer uma delas com resposta vaga interrompe o framework: ou se torna específica, ou a iniciativa não passa.

Pergunta 1 — Tarefa

“O que exatamente a IA vai fazer?” Verbo + objeto + critério de sucesso, em uma frase.

Exemplo aceitável: “Classificar tickets de suporte em uma de cinco categorias com F1 mínimo de 0,85 contra rótulo humano”.
Exemplo não aceitável: “Ajudar o time de suporte com IA”.

Pergunta 2 — Operador

“Quem opera, com que critério de aceitação?” Pessoa nominal e regra explícita de quando aceita a saída.

Se a resposta for “ninguém define” ou “o usuário decide”, a iniciativa não passa. Voltar à pergunta 1 e estreitar.

Pergunta 3 — Risco

“O que acontece se a saída estiver errada? Reversível ou não?” Tipologia: financeiro, jurídico, reputacional, clínico, operacional. Reversibilidade em escala de quatro: totalmente reversível (idempotente), reversível com custo (compensável), parcialmente reversível, irreversível.

Pergunta 4 — Linha de medição

“Como saberemos que está funcionando?” Métrica primária + golden set inicial + frequência de revisão.

Sem golden set planejado, a iniciativa pode passar para piloto interno mas não para produção. Inv. 7 manda.

Pergunta 5 — Responsabilidade

“Quem assina?” Nome próprio, com cadeira específica, com competência para responder pela decisão.

Sem nome, não passa. Inv. 8 manda.

3. OUTPUT

A saída do F1, em uma página, contém:

Campo	Conteúdo
Vai / Não-vai	Decisão binária com justificativa em uma frase
Nível de autonomia	Assistente · Co-piloto · Agente supervisionado · Agente autônomo regulado (define-se via F3 AGENTE-PROP)
Plano de eval	Golden set inicial, métrica primária, gate de bloqueio (via F8 EVAL-PIRÂMIDE)
Dono nominal	Nome + cadeira + cláusula de accountability
Revisão programada	Quando o framework volta a rodar para reavaliar

4. EXEMPLO DE USO

Pergunta	Resposta concreta
1 – Tarefa	Triar currículos em “candidato com fit > 0,7 contra rubrica do hiring manager” (NÃO decisão de contratação)
2 – Operador	Recrutador sênior + hiring manager; aceitação se humano revisa top-15 antes de contato
3 – Risco	Reputacional alto (alegação de discriminação); irreversível em reputação; reversível em decisão
4 – Linha de medição	Golden set de 400 currículos com gabarito de sêniore; viés $\leq 2\%$ em adversarial de variantes equivalentes; revisão trimestral
5 – Responsabilidade	Diretor de RH + DPO assinam Caderno de Governança da iniciativa

Decisão: vai como **assistente** (humano decide sempre), nunca como decisor único. Eval comportamental mensal (Cap 41). Auditoria de viés trimestral (Cap 42). Política de transparência com candidato.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
Pular a pergunta 2 (operador)	Iniciativa fica sem dono operacional; falha quando precisa iterar
Pular a pergunta 5 (responsabilidade)	Falha jurídica e institucional quando der ruim
Aceitar “depois a gente decide isso” em qualquer pergunta	Toda dúvida adiada vira incidente
Aplicar o framework retroativamente, em iniciativa já em produção, sem corrigir buracos	Vira teatro de processo

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 39 — Evals (linha de medição da Pergunta 4)
- □ Cap 40 — LLMOps (nível de autonomia da Pergunta 3)
- □ Cap 42 — Governança (responsabilidade nominal da Pergunta 5)
- □ F3 — AGENTE-PROP (decide o nível de autonomia)
- □ F6 — GOV-INDELEGÁVEL (governança da iniciativa)
- □ F8 — EVAL-PIRÂMIDE (plano de eval da iniciativa)

“Vai ou não-vai não é palpite, é resposta a cinco perguntas duras. Quem pula uma delas paga depois.”

FRAMEWORK F2 —

ENCAIXE-5

Escolha de modelo por 5 eixos de tarefa

□ **Invariante-mãe: Invariante 4 — Encaixe** — “Escolha pelo padrão da tarefa, nunca pela versão da moda.” Capítulo-âncora: *Cap 15 — Comparação dos principais modelos*. Aplicação Claude: *Cap 18 — Modelos Claude*. Números correntes: *Apêndice Vivo (J)*.

1. OBJETIVO

Decidir qual modelo usar para uma tarefa específica, sem cair em “modelo do mês”. A decisão é função do **padrão da tarefa** (durável), não da liderança da semana em benchmark agregado (volátil).

2. FUNCIONAMENTO

Pontuar a tarefa de 0 a 5 em cinco eixos canônicos, e aplicar a matriz de perfis de família. Modelo escolhido é o de **melhor encaixe ponderado**, não o de melhor benchmark agregado.

Os 5 eixos

Eixo	O que pontuar	Família que tende a vencer
Ra- zão com- plexa	Tarefas com múlti- plos passos, audi- toria do percurso, decisão lógica en- cadeada	Premium dos três frontier; thinking- models open
Có- digo	Edição de código real, com testes, contexto longo, re- fatoração	Família Claude (Opus) em SWE-bench Verified, historicamente
Con- texto longo	Análise de docu- mentos extensos, bases volumosas, múltiplos arquivos	Família Gemini Pro (pelo tamanho de janela típico)
Mul- ti- mo- dal	Vídeo, imagem, áu- dio nativos; OCR, leitura de gráfico	Família Gemini Pro
Cus- to críti- co	Volume altíssimo, margem apertada, classificação sim- ples em produção	Variantes Flash/Haiku/Mini; open source self-hosted

Mecânica de aplicação

- 1. **Pontuar a tarefa** de 0 a 5 em cada eixo. Notas altas indicam que o eixo importa muito para essa tarefa.
- 2. **Identificar o eixo dominante** (maior nota). Se houver empate entre dois ou três eixos, marcar todos.
- 3. **Consultar o Apêndice Vivo** para a família corrente que lidera cada eixo dominante.
- 4. **Escolher pelo melhor encaixe**, com fallback explícito. Se o eixo dominante é “código” + “razão complexa”, o premium da família com força em ambos vence.
- 5. **Definir critério de reavaliação**: a cada seis meses, a cada lançamento de mesmo eixo, ou conforme custo cruzar limite.

3. OUTPUT

Campo	Conteúdo
Tarefa pontuada nos 5 eixos	Tabela 5×1 com notas
Eixo(s) dominante(s)	1 a 3 eixos com nota ≥4
Modelo escolhido	Família + tier + variante específica (com link ao Apêndice Vivo)
Modelo fallback	Para resiliência ou cost ceiling
Critério de reavaliação	Cadência e gatilho

4. EXEMPLOS DE USO

Exemplo A — Classificação de e-mail em larga escala (5M/mês)

Eixo	Nota
Razão complexa	1
Código	0
Contexto longo	1
Multimodal	0
Custo crítico	5

Eixo dominante: **custo crítico**. Encaixe: variante pequena (Haiku-like) com prompt enxuto ou fine-tuning leve. Fallback: variante pequena de outro vendor. Reavaliação: trimestral ou quando volume mudar de magnitude.

Exemplo B — Agente de engenharia para refatoração de código legado

Eixo	Nota
Razão complexa	5
Código	5
Contexto longo	4
Multimodal	0
Custo crítico	2

Eixos dominantes: **código + razão complexa + contexto longo**. Encaixe: premium da família Claude (Opus) com Claude Code. Fallback: premium concorrente para tarefas onde matemática lidera. Reavaliação: a cada release relevante; teste cego comparado em PRs reais.

Exemplo C — Análise de relatório técnico com gráficos e tabelas

Eixo	Nota
Razão complexa	3
Código	0
Contexto longo	4
Multimodal	5
Custo crítico	2

Eixos dominantes: **multimodal + contexto longo**. Encaixe: Gemini Pro pela liderança em multimodal e janela grande. Fallback: variante balanceada de Claude para texto + chamada multimodal específica para o anexo. Reavaliação: semestral.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
“Lançou novo, vou trocar”	Migração sem teste cego na própria carga troca problema conhecido por desconhecido
Usar Opus para tudo “porque é o melhor”	Viola Inv. 5; em meses, a fatura mostra o erro
Não ter fallback	Vendor outage vira incidente para o cliente final
Decidir por benchmark agregado	Esconde força em eixo específico que importa para sua carga
Reavaliar só quando “a equipe quiser”	Sem cadência fixa, vira reação ao boato da semana

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 15 – Comparação de modelos
- □ Cap 18 – Modelos Claude (L2)
- □ Apêndice Vivo (J)
- □ F5 – MCP-COBERTURA (decisão complementar para integração)
- □ F7 – COMPOSTO-3T (decisão de tier como vetor de custo)

“Padrão da tarefa não muda toda rodada. Líder da rodada muda toda rodada. Decida pelo que dura.”

FRAMEWORK F3 —

AGENTE-PROP

Arquitetura de agentes por autonomia proporcional

□ **Invariante-mãe: Invariante 6 — Autonomia Proporcional** —
“Só dê ao agente a autonomia que você consegue medir e desfazer.” Capítulo-âncora conceitual: *Cap 12 — Agentes de IA*.
Capítulo-âncora operacional: *Cap 40 — LLMOps*. Aplicação Claude: *Cap 24 Claude Code, Cap 32 Subagents*.

1. OBJETIVO

Decidir o nível de autonomia que um agente pode receber, em função direta de duas capacidades operacionais: **rastrear** (observabilidade) e **reverter** (rollback). Garantir que autonomia delegada nunca exceda a proporção que o time consegue medir e desfazer.

2. FUNCIONAMENTO

Matriz 4×4 cruzando observabilidade × reversibilidade. O quadrante de encontro determina o nível máximo de autonomia permitido na iniciativa.

Eixos da matriz

Eixo X — Observabilidade disponível: 1. Nenhuma (só log de erro) 2. Logs estruturados de input/output 3. Tracing por span (input, output, latência, tokens, custo por passo) 4. Tracing + replay (capacidade de reproduzir a execução completa)

Eixo Y — Reversibilidade da ação: 1. Nenhuma (irreversível — envio externo, comunicação a cliente, transação financeira) 2. Compensável (existe ação de desfazer com custo) 3. Totalmente reversível (rollback automático, idempotente) 4. Sem efeito externo (só leitura, simulação)

Os 4 níveis canônicos de autonomia

Nível	Quando aplicar	Tipo de ação permitida
Assis- tente	Observabilidade 1-2 OU reversibilidade 1 sem rollback	Gera proposta; humano executa
Co-pi- loto	Observabilidade 2-3 + reversibilidade 2	Executa com confirmação a cada passo crítico
Agente super- visio- nado	Observabilidade 3 + reversibilidade 3 + humano monitora trace em tempo real	Executa em lote; humano interrom- pe se algo errado
Agente autô- nomo regu- lado	Observabilidade 4 + reversibilidade 3-4 + eval online + kill switch testado	Executa em produção sem supervi- são direta, com gates de promoção

Gates de promoção entre níveis

Promoção entre níveis exige: 1. **Métrica de qualidade** estável por N dias (N depende da carga; tipicamente 14-30 dias) 2. **Zero incidentes** SEV-1 ou SEV-2 no período 3. **Custo composto** dentro do envelope acordado 4. **Aprovação nominal** do dono operacional (Inv. 8) 5. **Plano de rollback** testado no nível em questão

Rebaixamento é automático: incidente SEV-1 ou SEV-2 desativa promoção até nova análise.

3. OUTPUT

Campo	Conteúdo
Nível atual autorizado	Assistente / Co-piloto / Supervisionado / Autônomo regulado
Tools permitidas no nível	Lista com permissões (read-only, write com confirmação, write livre)
Gates de promoção	Condições explícitas e mensuráveis para subir de nível
Critérios de rebaixamento	Triggers que retornam o agente a nível anterior
Kill switch	Quem aciona, em quantos segundos, e como testar
Plano de rollback	Estado anterior em hot standby; teste mensal documentado

4. EXEMPLO DE USO

Caso: agente que envia e-mail externo de boas-vindas em onboarding de cliente B2B.

Dimensão	Avaliação
Observabilidade	Tracing por span existe (3); replay não
Reversibilidade da ação	Compensável (e-mail de apologia, escalonamento humano) – nível 2
Quadrante de encontro	Observabilidade 3 + reversibilidade 2 → Co-piloto

Decisão inicial: agente opera como co-piloto, com confirmação humana a cada e-mail antes do envio nos primeiros 30 dias.

Gates de promoção a agente supervisionado: zero reclamação de cliente em 30 dias, taxa de aprovação humana >95%, eval comportamental sem regressão. Após promoção, humano monitora trace em dashboard mas não confirma cada envio.

Gate de promoção a agente autônomo regulado: após mais 60 dias de operação supervisionada sem incidente, implementação de replay completo (atinge observabilidade 4), kill switch testado em simulado mensal.

Kill switch: desliga via feature flag em ≤30 segundos. Testado mensalmente em staging com rollback simulado. Dono: VP de Customer Success.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
Agente autônomo com escrita em produção sem tracing	Passivo, não ativo; incidente vira investigação de semanas
“A IA é boa, podemos confiar” como justificativa de pular níveis	Quando ela falhar (e vai), não há observabilidade para reconstruir
Kill switch teórico (existe no roadmap, nunca foi testado)	Na hora do incidente, descobre-se que não funciona
Rollback documentado, nunca exercitado	Rollback que não é testado, na hora não funciona
Tratar todos os agentes da empresa no mesmo nível	Ignora variação real de risco entre casos de uso

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 12 — Agentes
- □ Cap 40 — LLMOps (os 7 pilares operacionais sustentam o framework)
- □ Cap 24 — Claude Code (L2)
- □ Cap 32 — Subagents (L2)
- □ F1 — DECID-IA (passo 3 do F1: define o risco; F3 decide o nível)
- □ F8 — EVAL-PIRÂMIDE (eval suporta promoção entre níveis)
- □ F6 — GOV-INDELEGÁVEL (Inv. 8 sustenta o “dono” de cada nível)

“Autonomia sem rollback testado é passivo no balanço. Não importa que esteja funcionando hoje.”

FRAMEWORK F4 — PROMPT-EXT

Engenharia de prompts pelas extremidades

□ **Invariante-mãe: Invariante 2 — Extremidades** — “O meio do contexto é onde a informação vai morrer.” Invariante secundário: **Inv. 3 — Camada Dupla** (separa o padrão durável do conteúdo da chamada). Capítulos-âncora: *Cap 04 — Janela de contexto, Cap 09 — Engenharia de prompt, Cap 11 — Context Engineering.*

1. OBJETIVO

Escrever prompts de produção que respeitam a física de atenção (Inv. 2) e que separam, dentro do prompt, o que é padrão estável do que é número volátil (Inv. 3). Garantir que a regra crítica nunca fique no centro do prompt, e que cada bloco esteja na posição em que será efetivamente seguido.

2. FUNCIONAMENTO

Estrutura canônica em **5 blocos**, com regras explícitas de posição.

Bloco 1 — Persona e missão (topo do prompt)

Curto, claro, ancorado. Diz o que o modelo é e qual o seu objetivo no fluxo. Esta posição recebe a maior parte da atenção do modelo, e por isso carrega a definição que precisa permear toda a resposta.

Exemplo: “Você é o agente de atendimento ao cliente do Banco Solar. Sua missão é resolver o caso do cliente em até três respostas, ou escalar para humano com sumário estruturado.”

Bloco 2 — Constituição (regras invioláveis, imediatamente após persona)

Pequeno, denso, em bullets curtos. Aqui ficam as regras que **nunca podem ser quebradas**, e que precisam estar próximas da persona para receberem peso adequado. É a parte do prompt que sobrevive entre chamadas — versionada, revisada, governada. É a Camada Dupla materializada: padrão estável.

Exemplo: Constituição: — Nunca afirmar saldo sem consultar a tool `consulta_saldo`. — Em qualquer suspeita de fraude, escalar imediatamente para humano. — Nunca prometer ressarcimento; só humano autoriza. — Comunicação sempre em pt-BR formal, sem expressões coloquiais.

Bloco 3 — Contexto da tarefa atual (meio do prompt)

Pode ser maior. Documentos, exemplos, dados, histórico de conversa. Esta é a parte que recebe **menos atenção em prompts longos** — por isso, **nada crítico vai aqui**. Conteúdo do meio é informação de apoio, não regra.

Bloco 4 — Instrução operacional + formato esperado (imediatamente antes da pergunta viva)

Curto. Posição forte (a segunda mais atendida, depois da abertura). Repete o crítico das regras na linguagem da tarefa específica, e define o formato exato da saída esperada.

Exemplo: “Responda em pt-BR formal, máximo três parágrafos, sem expressões coloquiais. Cite a tool consultada quando aplicável. Se não conseguir resolver, escale para humano com sumário em 3 bullets.”

Bloco 5 — Pergunta viva / input do usuário (última posição)

Sempre na última posição. Sempre. Sanitizada contra prompt injection. Esta é a única parte do prompt que muda em cada chamada — a Camada Dupla materializada: número volátil.

3. OUTPUT

O F4 produz um prompt que se lê assim:

[BLOCO 1 – PERSONA E MISSÃO]

(curto, 1-3 linhas)

[BLOCO 2 – CONSTITUIÇÃO]

(bullets curtos, 4-8 itens)

[BLOCO 3 – CONTEXTO]

(documentos, exemplos, dados, histórico)

[BLOCO 4 – INSTRUÇÃO OPERACIONAL + FORMATO]

(reitera o crítico, define output)

[BLOCO 5 – PERGUNTA VIVA]

(input do usuário, sanitizado)

4. EXEMPLO DE USO

Caso: agente de revisão de contrato em escritório de advocacia.

Você é o agente de revisão de contratos comerciais do escritório Vianna, Castro e Almeida. Sua missão é identificar cláusulas atípicas, com base nos padrões da banca, e produzir parecer estruturado em até cinco minutos de processamento.

[CONSTITUIÇÃO]

- Nunca afirmar cláusula sem citar o trecho literal e a localização (página e parágrafo).
- Em qualquer cláusula de mudança de controle, change of control ou MAC, marcar como red flag SEV-1 mesmo se redação parecer padrão.
- Nunca recomendar assinatura ou rejeição: produzir parecer; sócio decide.
- Idioma de saída: pt-BR técnico. Citações no idioma original do contrato.

[CONTEXTO]

[Inserir aqui: trechos relevantes do contrato, padrões da banca, casos similares de DD anteriores, glossário de cláusulas-alvo.]

[INSTRUÇÃO OPERACIONAL]

Produza parecer em três seções: (1) sumário executivo em 5 bullets;
(2) red flags SEV-1 e SEV-2 com citação literal de página/parágrafo;
(3) cláusulas padrão verificadas com nota de "normal" ou "negociar".
Não recomende assinatura. Em qualquer cláusula change of control, marcar SEV-1 mesmo se redação parecer padrão.

[PERGUNTA VIVA]

```
[Input do operador: pergunta específica sobre o
contrato em análise]
```

A constituição vive em artefato versionado (Skills no L2). O contexto muda por contrato. A pergunta viva muda por chamada. O bloco 4 reitera as regras críticas porque, mesmo com a constituição no topo, **a chamada do modelo termina pelo bloco 4** — daí a redundância deliberada.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
Enterrar regra crítica no parágrafo 40 de prompt longo	Inv. 2: atenção decai no meio; regra ignorada silenciosamente
Colocar a pergunta no início, antes do contexto	Modelo responde ao input sem ter visto o contexto
Constituição não versionada (string no código)	Sem rastreabilidade de mudança; vira buraco de governança
Misturar regra inviolável com sugestão estilística	Modelo perde hierarquia; quebra ambas com a mesma facilidade
Não reiterar o crítico no bloco 4	Em prompts longos, o final domina; sem reiteração, regra do topo enfraquece
Não sanitizar a pergunta viva	Prompt injection via input do usuário sobrescreve a constituição

6. CONEXÕES

- □ Manifesto dos Invariantes

- □ **Cap 04 — Janela de contexto**
 - □ **Cap 09 — Engenharia de prompt**
 - □ **Cap 11 — Context Engineering**
 - □ **Cap 20 — Projects (L2)** — Projects materializam o bloco de constituição
 - □ **Cap 31 — Skills (L2)** — Skills versionam o bloco de constituição como ativo
 - □ **F8 — EVAL-PIRÂMIDE** — o adversarial set inclui prompt injection contra a pergunta viva
-

“A regra que importa não vai no meio do prompt. Vai na primeira posição forte e na última. Quem coloca no centro está rezando para a atenção do modelo, e a atenção não está olhando.”

FRAMEWORK F5 — MCP-COBERTURA

Decisão de adoção de MCP por quadrante

□ **Invariante-mãe: Invariante 6 — Autonomia Proporcional** — “Só dê ao agente a autonomia que você consegue medir e desfazer.” Invariante secundário: **Inv. 4 — Encaixe** (padrão maduro × padrão ad-hoc). Capítulos-âncora: **Cap 13 — MCP**, **Cap 33 (L2) — Claude + MCP**.

1. OBJETIVO

Decidir, por *capability* (capacidade), se vale adotar **MCP existente público**, **MCP self-hosted**, **MCP próprio** ou **tool ad-hoc** — sem cair no extremo de “tudo MCP” (over-engineering) nem no de “nada MCP” (lock-in artesanal). A decisão é função do **padrão maduro disponível** e da **sensibilidade dos dados** envolvidos.

2. FUNCIONAMENTO

Matriz 2x2 cruzando padrão maduro × sensibilidade de dados. Cada quadrante dita o tipo de MCP correto.

Eixos da matriz

Eixo X — Padrão maduro disponível? - Sim: existe MCP público bem mantido, com comunidade ativa, governança clara - **Não:** sem padrão estabelecido; ou existe mas é experimental, abandonado, sem dono claro

Eixo Y — Sensibilidade dos dados? - Alta: dados sob LGPD/regulação, segredos comerciais, PII, dados de cliente em produção - **Baixa:** dados públicos, dados de teste, contexto sem implicação regulatória

Os 4 quadrantes

Quadrante	Condição	Decisão	Exemplo típico
A	Padrão maduro + dados não sensíveis	Adotar MCP público	Calendar, Notion público, GitHub public APIs, Google Search
B	Padrão maduro + dados sensíveis	MCP self-hosted ou variante privada	Slack workspace privado, Salesforce, GitHub enterprise
C	Sem padrão + dados não sensíveis	Tool ad-hoc até virar padrão	API interna nova, integração experimental
D	Sem padrão + dados sensíveis	MCP próprio com auditoria completa	Core bancário, sistemas regulados, PHI/PII em saúde

Mecânica de aplicação

1. Listar as *capabilities* (capacidades) que a operação precisa que o agente acesse — leitura, escrita, busca, execução em sistemas terceiros
2. Para cada capability, pontuar os dois eixos
3. Aplicar o quadrante correspondente
4. Documentar: dono nominal por MCP, política de auditoria, política de versionamento, plano de migração se quadrante mudar

3. OUTPUT

Campo	Conteúdo
Lista de capabilities	O que o agente precisa acessar
Quadrante por capability	A/B/C/D justificado
Tipo de MCP escolhido	Público / self-hosted / ad-hoc / próprio
Dono nominal por MCP	Pessoa responsável + cadeira
Política de auditoria	Frequência, escopo, retenção
Plano de migração	Quando o quadrante mudar

4. EXEMPLO DE USO — BANCO SOLAR (FINTECH)

Caso composto: fintech BR precisa expor ao agente conjuntos diversos de capability.

Capa- bility	Eixo X (padrão ma- duro?)	Eixo Y (sensibilida- de?)	Qua- drante	Deci- são
Calen- dário do aten- dente	Sim (Google Calen- dar MCP)	Baixa	A	MCP pú- blico
Co- nheci- mento públi- co de pro- duto	Sim (Notion público)	Baixa	A	MCP pú- blico
Slack works- pace inter- no (notifi- ca- ções)	Sim (Slack MCP)	Alta	B	MCP self- hos- ted ou vari- ante pri- vada
CRM da fin- tech (Sales- force)	Sim	Alta	B	MCP self- hos- ted
Siste- ma novo de tickets (lança-	Não	Baixa	C	Tool ad- hoc até virar

Capa- bility	Eixo X (padrão ma- duro?)	Eixo Y (sensibilida- de?)	Qua- drante	Deci- são
do mês passa- do)				pa- drão
Core bancá- rio (con- sulta saldo, abre con- testa- ção)	Não	Alta	D	MCP pró- prio com audi- toria com- pleta

Resultado: o Banco Solar opera 4 categorias de MCP simultanea-
mente, com governança específica para cada quadrante. Capabi-
lity do quadrante D (core bancário) tem dono nominal de área de
tecnologia + DPO + Compliance, auditoria a cada release, retenção
de log por 5 anos.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
“Tudo MCP” (over-engineering)	Capability nova sem padrão maduro vira projeto de plataforma que atrasa entrega
“Nada MCP” (lock-in artesanal)	Toda integração vira tool específica; agente fica frágil; manutenção explode
MCP público para dados sensíveis	Risco regulatório e de vendor — o servidor MCP pode logar, vaziar, mudar
MCP próprio sem auditoria	Cria o falso conforto de “está sob controle” sem sustentar a alegação
Não documentar o quadrante por capability	Decisão é refeita por cada engenheiro novo, sem critério
Não monitorar quando o quadrante mudou	Capability C que virou padrão maduro precisa migrar para A; ninguém percebe

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 13 — MCP
- □ Cap 33 (L2) — Claude + MCP
- □ Cap 34b (L2) — Connectors, Dispatch, Routines
- □ F3 — AGENTE-PROP (níveis de autonomia limitam permissões por MCP)

- □ **F6 — GOV-INDELEGÁVEL** (cada MCP tem dono nominal)

“Tool ad-hoc é dívida técnica disfarçada. MCP público sem auditoria é risco regulatório disfarçado. MCP próprio sem dono é teatro disfarçado. O quadrante decide qual disfarce você vai vestir.”

FRAMEWORK F6 — GOV-INDELEGÁVEL

Governança de IA aplicada — 3 camadas × 10 controles

□ **Invariante-mãe: Invariante 8 — Responsabilidade Indelegável** — “A IA executa; a responsabilidade tem sempre um nome humano.” Capítulo-âncora: *Cap 42 — Governança de IA corporativa*. Aprofundamento: *Cap 37 — Segurança*. Aplicação Claude: *Cap 30 (L2) — Enterprise*.

1. OBJETIVO

Construir governança de IA que **protege o negócio sem virar teatro de compliance**. Saída: Caderno de Governança v1 com política em ≤6 páginas + RACI assinado + plano de incidente testado em simulado + matriz de maturidade dos 10 controles.

2. FUNCIONAMENTO

Governança real opera em **três camadas** que **precisam fechar**, sustentadas por **dez controles canônicos**.

As 3 camadas

Camada	O que cobre	Quem responde
Técnica	Acesso, auditoria imutável, kill switch, rollback, observability, evals em CI	CTO / Head de tecnologia
Operacional	RACI, AUP, política de incidentes, runbooks, treinamento, postmortem	Head de operações / VP de produto
Executiva	AI Council, política pública, accountability nominal, comitê de ética, comunicação com conselho	CEO / Diretor com mandato

Cada camada tem dono nominal. Sem nome em cada camada, governança não fecha – vira documento publicado sem prática efetiva.

Os 10 controles canônicos

#	Controle	Camada
1	Controle de acesso por feature, por usuário, por papel	Técnica
2	Auditoria imutável de cada chamada de IA em produção	Técnica
3	Kill switch testado por tool, por agente, por modelo, por feature	Técnica
4	Rollback testado mensalmente em staging	Técnica
5	Observability com tracing (pilares 1 de LLMOps)	Técnica
6	Evals em CI com critério de bloqueio explícito	Técnica
7	RACI de IA assinado pela diretoria	Operacional
8	Política de Uso Aceitável (AUP) publicada e treinada	Operacional
9	Política de incidentes testada em simulado trimestral	Operacional
10	AI Council com mandato e cadência fixa	Executiva

Mecânica de aplicação

- 1. **Diagnóstico de maturidade.** Pontuar cada um dos 10 controles em escala 0-4 (inexistente, declarado, implementado, auditado, melhoria contínua).

- 2. **Identificação de buracos.** Controles em maturidade ≤ 1 são prioridade. Maturidade 2 sem auditoria é teatro.
- 3. **Plano em 90/180/365 dias.** Cada controle com maturidade-alvo, dono, gate de promoção.
- 4. **Caderno em ≤ 6 páginas.** Política + RACI + plano de incidente + matriz de maturidade.
- 5. **Revisão trimestral.** Maturidade atualizada, plano ajustado, incidentes do trimestre integrados.

3. OUTPUT

Campo	Conteúdo
Política em ≤ 6 páginas	AUP + princípios + categorias de safety
RACI assinado	8 papéis $\times$ 12 decisões mínimas
Plano de incidente testado	Severidades, comunicação, postmortem
Matriz de maturidade	10 controles em escala 0-4, com meta de 90/180/365 dias
Donos nominais por cama-da	Técnica, Operacional, Executiva
Cadência de revisão	Trimestral, com pauta fixa

4. EXEMPLO DE USO — SEGURADORA APÓS INCIDENTE (CENÁRIO ILUSTRATIVO)

Seguradora BR de médio porte, após multa ANPD por negação automatizada de cobertura sem trilha de auditoria.

Diagnóstico de maturidade pré-incidente:

Controle	Maturidade
1 Acesso	1 (declarado)
2 Auditoria	0
3 Kill switch	0
4 Rollback	1
5 Observability	1
6 Evals em CI	0
7 RACI	0 (implícito, “o time de dados cuida”)
8 AUP	0
9 Política de incidentes	1 (documento sem teste)
10 AI Council	0

Plano após incidente (90 dias):

- Controle 7 (RACI): assinado pela diretoria com 8 papéis (CTO, Head Dados, DPO, Head Compliance, Diretor Operações, Diretor Comercial, Diretor Jurídico, CEO) × 12 decisões (modelo,

prompt, dataset, agente, MCP, tool, incidente SEV-1, política, etc.)

- Controle 8 (AUP): 4 páginas, publicada, treinada em todo o time em ≤ 30 dias
- Controle 2 (Auditoria): retenção 5 anos para decisão automatizada com efeito jurídico
- Controle 6 (Evals em CI): golden set inicial para classificação de cobertura
- Controle 9 (Incidente): simulado trimestral com cronômetro
- Controle 10 (AI Council): mandato escrito, cadência mensal nos primeiros 6 meses

Após 7 meses: matriz com 8 de 10 controles em maturidade ≥ 3 . Multa não voltou. Seguradora apresenta caso em comitê setorial como exemplo de remediação.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
Política publicada, processo inexistente, prática divergente	Governança morta no PDF; quando o incidente vier, o documento será exposto como teatro
RACI implícito (“o time X cuida”)	Sem nome, ninguém responde. Inv. 8 viola por omissão
AI Council sem mandato	Vira reunião de tom sem decisão; conselho fica simbólico
Política de incidente nunca testada em simulado	Na hora do incidente, descobre-se que não funciona
Auditoria interna sem auditoria externa periódica	Auto-auditoria tende a falsa segurança
“Vamos terceirizar o problema”	Compliance terceirizado vira processo terceirizado; accountability não terceiriza

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 37 – Segurança
- □ Cap 41 – Alignment (sustenta safety em produto)
- □ Cap 42 – Governança
- □ Cap 29 (L2) – Team, Cap 30 (L2) – Enterprise
- □ F1 – DECID-IA (Pergunta 5 – Responsabilidade – alimenta o RACI)

- □ **F3 — AGENTE-PROP** (níveis de autonomia precisam de governança proporcional)
-

*“Governança não é documento publicado, é controle aplicado.
Quem confunde, descobre na multa ou no processo.”*

FRAMEWORK F7 — COMPOSTO-3T

Adoção corporativa pelos 3 vetores arquiteturais de custo composto

□ **Invariante-mãe: Invariante 5 — Custo Composto** — “Trivial é o preço do token; o que quebra o orçamento é quantas vezes você o paga.” Invariante secundário: **Inv. 9 — Operador** (operação madura aplica em ordem certa). Capítulo-âncora: **Cap 36 — Economia de Tokens em profundidade**. Fundamento: **Cap 03 — Tokens** e **Cap 07 — Memória**.

1. OBJETIVO

Atacar o orçamento real de IA na empresa pelo lado certo — **arquitetural** — não pelo lado errado — **textual**. Garantir que esforço de otimização vai onde o termo composto escala, não onde aparece o termo trivial.

2. FUNCIONAMENTO

A fórmula do Custo Composto:

```
Custo Total = Σ (tokens_in × preço_in + tokens_out ×
preço_out)
            × chamadas
            × redundância
            × tier
```

O framework opera em **três alavancas arquiteturais** (os “3T”), em ordem fixa de impacto e de risco.

T1 — Tier de modelo

O que é: rotear cada chamada ao **modelo mais barato suficiente** para a qualidade exigida.

Mecânica. - Classificador leve (Haiku-like) na entrada da pipeline decide rota. - Tarefas estruturadas, classificação binária, extração de campo → tier pequeno (Haiku). - Tarefas de razão balanceada, sumarização, resposta em escala → tier balanceado (Sonnet). - Tarefas críticas de razão profunda, código complexo, escrita executiva → tier premium (Opus).

Implementação. 1-3 semanas para versão inicial; classificador é prompt simples ou pequeno modelo dedicado.

Economia típica observada. 30% a 60% do gasto total na primeira virada de roteamento, em operações que usavam premium para tudo.

Risco. Médio. Exige golden set para mostrar que tier pequeno entrega qualidade equivalente (Invariante 7 sustenta a decisão).

T2 — Topologia de chamada

O que é: reduzir **redundância** dentro do fluxo, sem mexer em tier nem em prompt.

Mecânica. - **Prompt caching** para prefixos estáveis (system prompt, instruções recorrentes). - **Batching** de chamadas independentes. - **Eliminação de loops** de agente que reconsultam o mesmo dado. - **Circuit breaker** contra runaway loops por usuário ou sessão. - **Tool design** que devolve em uma chamada o contexto que o próximo passo precisa.

Implementação. 2-4 semanas para o conjunto inicial; depende do quanto a arquitetura já está modular.

Economia típica observada. 20% a 50% adicional, após T1.

Risco. Médio-alto. Mudanças em topologia podem introduzir regressão se o pilar 1 de LLMOps (tracing) e o pilar 3 (deploy progressivo) não estiverem maduros.

T3 — Tamanho de contexto

O que é: podar agressivamente o que entra no contexto da chamada.

Mecânica. - **RAG enxuto:** top-k baixo após reranking; chunks compactos; descarte de duplicidade. - **Compressão de histórico:** sumarização hierárquica de turnos antigos. - **Expiração de memória:** turnos com idade ou irrelevância vão para sumário ou são descartados. - **Bibliografia controlada:** evitar inflar context com documentação que não está sendo consultada.

Implementação. 1-3 semanas, depende de quanto havia de “carona” no contexto.

Economia típica observada. 15% a 40% adicional, após T1 e T2.

Risco. Baixo. Exige eval cuidadoso para detectar regressão de qualidade por contexto insuficiente.

Ordem de aplicação

Mexer em T3 antes de T1 é o erro mais comum, porque T3 é o mais visível (“vamos cortar palavras do prompt”). Visível e marginal. A ordem é T1 → T2 → T3.

3. OUTPUT

Campo	Conteúdo
Análise atual de custo por feature	Atribuição via Pilar 5 de LLMOps
Identificação do componente que mais escala	Tokens, chamadas, redundância ou tier
T1 plan	Quais features migrar de tier, em que ordem, com qual golden set
T2 plan	Onde implementar caching, batching, circuit breaker
T3 plan	RAG enxuto, compressão de histórico, expiração de memória
Meta de economia	% por T, por feature, por trimestre
Eval que sustenta cada mudança	Inv. 7 — sem eval, não muda

4. EXEMPLO DE USO — PÓLICE.IO PÓS-INCIDENTE

Marketplace BR de seguros, após o incidente do loop com cartão de crédito (Cap 40).

Diagnóstico inicial. - Fatura mensal: R\$ 142 mil - Atribuição por feature: 87% concentrado no agente de cotação - Componente que mais escala: **redundância** (loop de agente reconsultando 7 seguradoras) - Tier dominante: 92% das chamadas vão para Opus, mesmo em classificação intermediária

Plano T1. Migrar classificação de intent (~38% do volume) para Haiku. Migrar geração de resposta padrão (~24%) para Sonnet. Manter Opus apenas para casos com sinal de complexidade alta (~15%).

Plano T2. Prompt caching para system prompt das cotações (eliminar 6.4kb por chamada). Circuit breaker de 5 chamadas Opus por sessão. Reescrita do agente para não reconsultar seguradoras em mudança de campo não-crítico (resolve o bug raiz do incidente).

Plano T3. RAG enxuto de documentação de produtos (top-3 chunks após reranking, em vez de top-20). Sumarização hierárquica em sessões com mais de 6 turnos.

Resultado em 3 meses. R\$ 142 mil → R\$ 47 mil, com volume servido maior. Distribuição final: 60% Haiku, 28% Sonnet, 12% Opus.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
Otimizar tamanho do prompt en- quanto agente loopa no Opus	Esforço no termo trivial, fatura segue subindo
Usar premium para classificação binária “por garantia”	30-50× o preço para entregar a mesma qualidade do pequeno
Começar por T3 porque é visível	T1 entrega ordem de magnitude a mais
Migrar tier sem golden set	Sem eval, regressão silenciosa em subgrupo
Ignorar atribuição de custo por feature	Sem atribuição, decisão de corte é tiro no escuro
Cortar caching para “simplificar”	Caching é o ROI mais alto de T2; descartar é multiplicar fatura

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 03 — Tokens, Cap 04 — Janela, Cap 07 — Memória
- □ Cap 11 — Context Engineering
- □ Cap 36 — Economia de Tokens (capítulo-âncora completo)
- □ Cap 40 — LLMOps Pilar 5 (atribuição de custo sustenta o framework)
- □ F2 — ENCAIXE-5 (decisão de tier do F2 alimenta o T1 do F7)
- □ F8 — EVAL-PIRÂMIDE (eval sustenta cada virada de T1)

“Preço por token é o termo trivial da fórmula. Quem otimiza só ali está mexendo onde menos dói. Os 3T mexem onde dói de verdade.”

FRAMEWORK F8 — EVAL-PIRÂMIDE

Pirâmide de Evals por criticidade

□ **Invariante-mãe: Invariante 7 — Termômetro** — “IA sem eval é fé, não engenharia.” Invariantes secundários: **Inv. 1** (Plausibilidade — eval comportamental detecta o que o modelo finge saber), **Inv. 8** (Responsabilidade — eval sustenta accountability técnica). Capítulo-âncora: **Cap 39 — Evals**. Aplicação operacional: **Cap 40 — LLMOps**. Aplicação comportamental: **Cap 41 — Alignment**.

1. OBJETIVO

Decidir **quanto investir em cada camada de eval**, em função do risco da tarefa e do custo de cada camada. Garantir que nenhum sistema entre em produção sem cobertura mínima e que recursos de eval mais caros (humano especialista) sejam alocados onde fazem diferença.

2. FUNCIONAMENTO

Hierarquia de três camadas verticais + uma faixa transversal. Cada camada cobre um percentual diferente da carga e tem custo diferente.

Base — Determinística

O que mede. Estrutura da saída, formato, campos críticos, presença de elementos obrigatórios.

Técnicas. Schema validation, exact match em campos críticos, regex para padrões obrigatórios, validações estruturais.

Cobertura. 100% das chamadas, em CI antes do merge e em produção como primeiro filtro.

Custo. Muito baixo. Implementação leva horas a poucos dias.

Detecta. Regressões grosseiras (formato quebrado, campo faltante, alucinação estrutural).

Meio — Golden Set + LLM-as-judge calibrado

O que mede. Qualidade semântica contra rubrica explícita, faithfulness, relevância, completude.

Técnicas. Golden set fixo com gabarito + LLM-as-judge aplicando rubrica calibrada contra humano em pelo menos 30 itens. Juiz diferente do gerador. Ensemble em decisões críticas.

Cobertura. 30% a 80% das chamadas conforme criticidade.

Custo. Médio. Implementação leva 1-4 semanas. Manutenção exige revisão do golden set e recalibração mensal do juiz.

Detecta. Regressão de qualidade que escapa da base. Cobre tarefas onde exact match não funciona (geração aberta).

Topo — Rubrica humana especialista

O que mede. Nuances específicas de domínio que LLM-as-judge não capta.

Técnicas. Revisão de amostra por especialista do domínio, em release crítico, em auditoria mensal ou trimestral, em incidente sob investigação.

Cobertura. 5% a 15% da carga, por amostra.

Custo. Alto. Demanda especialista do domínio em horas dedicadas.

Detecta. Erros sutis específicos do domínio. Calibra o juiz LLM contra o critério humano.

Transversal — Adversarial e segurança

O que mede. Casos que sabidamente quebram o sistema — jailbreak, prompt injection, conteúdo proibido, sycophancy, viés, honestidade de citação, over-refusal, calibração de incerteza.

Técnicas. Conjunto adversarial separado, renovado a cada trimestre. Casos vindos de produção (incidentes anteriores) e de literatura (HarmBench, JailbreakBench, BBQ).

Cadência. Mensal por padrão. Bloqueia release crítico se regredir.

Custo. Médio-alto. Exige curadoria contínua.

Detecta. Falhas comportamentais que as camadas verticais não cobrem por design.

3. OUTPUT

Campo	Conteúdo
Mapa de cobertura por camada	% atual em base, meio, topo, adversarial
Mapa-meta em 90 dias	% desejado por camada
Golden set inicial	30-50 casos representativos com gabarito
Rubrica de LLM-as-judge calibrada	4-6 critérios objetivos, com correlação alvo $\geq 0,7$ contra humano
Adversarial set inicial	20+ casos por categoria de segurança crítica
Política de bloqueio em CI	Delta que bloqueia merge, delta que alerta, delta que passa
Cadência de revisão	Golden set: trimestral. Adversarial: mensal. Calibração de juiz: mensal.

4. EXEMPLO DE USO — ATLAS STRATEGY PÓS-INCIDENTE

Consultoria estratégica BR, após o incidente dos números trocados no relatório (Cap 39).

Estado anterior. Vibe-eval (3 sócios na sexta). 0% de cobertura em qualquer camada da pirâmide.

Plano de pirâmide v1:

Camada	Cobertura	Conteúdo
Base	100%	Schema validation do relatório (seções obrigatórias, números formatados, citação presente)
Meio	100%	Golden set de 80 relatórios reais com gabarito de números e tese. LLM-as-judge com rubrica de faithfulness numérico (4 critérios). Juiz = Claude Opus (gerador = Sonnet). Calibrado contra 3 sócios em 30 itens, correlação 0,82
Topo	10%	Auditoria semanal de partner em release crítico. Trimestralmente, auditoria externa por consultor sênior independente
Adversarial	mensal	30 casos: paciente com sycophancy (cliente forçando conclusão), prompt injection via dado de cliente, números invertidos sutilmente, citação de fonte inexistente, omissão de risco crítico

Política de bloqueio. Faithfulness numérico $\geq 0,95$ (delta máximo 1 ponto contra baseline). Adversarial: zero passagens. Caso falhe, merge bloqueado automaticamente.

Resultado em 6 meses. Regressões silenciosas zeraram. Tempo de revisão humana caiu 50% — gate filtra ruído antes de o humano ver.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
Construir o topo da pirâmide sem a base	Humano revisa muito, identifica pouco, time não escala
LLM-as-judge sem calibração contra humano	Viés institucionalizado; auto-validação inflada
Golden set único, sem renovação	Vira folclore que não bate com produção atual
Adversarial só de literatura, sem casos de produção	Cobertura teórica, falhas reais escapam
Métrica única agregada (acurácia média)	Esconde regressão por subgrupo crítico
“Eval é caro” como justificativa para não fazer	Regressão silenciosa é mais cara, descoberta tarde

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 06 — RAG (RAGAS aplicado ao meio da pirâmide)
- □ Cap 08 — Fine-tuning (decisão sustentada por golden set)

- □ **Cap 39 — Evals** (capítulo-âncora completo)
 - □ **Cap 40 — LLMOps** (pilares 1, 2 e 3 sustentam o framework)
 - □ **Cap 41 — Alignment** (adversarial cobre 8 safety categories)
 - □ **Cap 42 — Governança** (eval em CI é controle técnico canônico)
 - □ **F1 — DECID-IA** (Pergunta 4 — linha de medição — alimenta o plano de pirâmide)
 - □ **F3 — AGENTE-PROP** (níveis de autonomia exigem cobertura proporcional na pirâmide)
-

“A pirâmide é barata na base, cara no topo. Quem inverte paga muito sem cobrir bem. Quem ignora paga em incidente.”

FRAMEWORK F9 — ROTA-DUPLA

Trilha de aprendizado e operação por camada (padrão × número)

□ **Invariante-mãe: Invariante 3 — Camada Dupla** — “Decore o padrão, consulte o número.” Capítulo-âncora: *Cap 01 — O que é IA* e o *Apêndice Vivo (J)*.

1. OBJETIVO

Orientar o estudo e a operação do leitor distinguindo, em cada peça de conhecimento, o que é **padrão (decora)** do que é **número (consulta)**. Garantir que tempo de aprendizado vá para o que envelhece bem, e que tempo de consulta vá para o que muda — com fonte e data.

2. FUNCIONAMENTO

Toda peça de conhecimento sobre IA pertence a **uma de duas trilhas** com cadências distintas de revisão.

Trilha Padrão (Padrão durável)

O que vai aqui. - Os 9 Invariantes da IA - Os 9 Frameworks proprietários (F1-F9) - Capítulos conceituais (Cap 01, 02, 03, 04, 05, 06, 07, 08, 09, 10, 11, 12, 13, 14) - Anatomia de eval, LLMOps, Alignment, Governança (Caps 39, 40, 41, 42) - Tradeoffs canônicos (Cap 43) - Padrões arquiteturais (RAG, agente, MCP, fine-tuning)

Cadência de revisitação. Trimestral para revisão completa. Anual para releitura focada.

Como armazena. Cabeça do operador. Cartaz dos Invariantes (Apêndice M) na parede. Caderno do Operador como notas pessoais.

Trilha Número (Número volátil)

O que vai aqui. - Versões correntes de modelos (Anthropic, OpenAI, Google, open weights) - Preços por milhão de tokens - Posições em benchmark da rodada (SWE-bench, GPQA, OSWorld, etc.) - Limites correntes de janela de contexto - Capacidades novas de produto (Claude Skills X.Y, Connectors, etc.) - Lista corrente de repositórios GitHub relevantes - Datas de regulação aplicável (versões de LGPD, AI Act, NIST AI RMF)

Cadência de revisitação. Mensal para conferência. Antes de cada decisão que use o número como insumo.

Como armazena. Apêndice Vivo (J) no Livro 2, datado, com fonte por linha, atualizado fora do livro.

Mecânica de aplicação

1. **Diagnóstico.** Listar o que se sabe sobre IA hoje. Para cada item, classificar: padrão ou número?

- 2. **Migração.** Item classificado errado vai para a trilha certa.
- 3. **Cadência de revisão.** Padrão entra em revisão trimestral. Número fica disponível para consulta sob demanda.
- 4. **Antes de cada decisão.** Identificar quais padrões e quais números a decisão precisa. Buscar cada um na trilha certa.

3. OUTPUT

Campo	Conteúdo
Mapa pessoal de padrões dominados	Os 9 Invariantes, frameworks F1-F9, conceitos centrais
Mapa pessoal de gaps de padrão	O que ainda precisa ser estudado
Calendário de revisão de padrão	Trimestral e anual
Bookmark do Apêndice Vivo	Para consulta de número
Calendário de checagem do Apêndice Vivo	Mensal por padrão; antes de cada decisão crítica

4. EXEMPLO DE USO — CTO QUE PRECISA DECIDIR MODELO

Cenário: CTO de SaaS B2B precisa decidir migração de modelo para feature de copiloto in-product.

Identificação do que a decisão precisa.

Insumo	Trilha	Onde buscar
Quais são os eixos relevantes para escolha de modelo?	Padrão	F2 ENCAIXE-5 (Trilha Padrão)
Como pontuar a tarefa nos eixos?	Padrão	Cap 15 + F2
Qual a liderança corrente em “razão complexa” e “código”?	Número	Apêndice Vivo (J) — SWE-bench Verified, GPQA
Qual o preço por milhão de tokens hoje?	Número	Apêndice Vivo (J) — pricing pages
Qual a filosofia de alignment do vendor?	Padrão	Cap 41 (depende pouco da versão)
Qual a janela de contexto corrente do modelo X?	Número	Apêndice Vivo (J)

A decisão é informada por padrão (F2 + Cap 41) e número (Apêndice Vivo). O padrão vive na cabeça do CTO; o número é conferido na semana da decisão.

Em 6 meses, a fronteira muda. Versões novas saem. Mas o padrão F2 continua válido. O CTO refaz o exercício, busca o novo número no Apêndice Vivo atualizado, e a decisão é consciente em vez de reativa.

5. ANTI-PADRÕES

Anti-padrão	Por que mata
Memorizar versão e benchmark “porque é importante”	Memória vira passivo no próximo release
Não memorizar o padrão “porque é teórico”	Sem padrão, decisão fica refém do marketing do vendor
Achar que o livro tem tudo	Livro tem o padrão; Apêndice Vivo tem o número
Confiar em memória para o número	Modelo X mudou de versão; preço caiu 40%; benchmark líder é outro
Ignorar o padrão porque “é óbvio”	Operadores que conhecem o óbvio cometem 80% dos erros do mercado
Atualizar o padrão na mesma cadência do número	Tempo gasto reescrevendo o que não mudou

6. CONEXÕES

- □ Manifesto dos Invariantes
- □ Cap 01 — O que é IA
- □ Cap 15 — Comparação de modelos
- □ Apêndice Vivo (J)
- □ Apêndice M — Manifesto de bolso
- □ Apêndice B — Mapa Mental Geral
- □ Todos os frameworks F1-F8 (cada um opera um padrão)

“Decore o padrão, consulte o número. Misturar as duas trilhas é envelhecer junto com o release.”