

Inteligência Aumentada

APÊNDICE G — PAPERS OBRIGATÓRIOS

35 papers que sustentam o estado da arte conceitual em IA generativa

Curadoria por categoria. Cada paper com 1-2 linhas explicando por que ler. Versões e papers correntes ficam no *Apêndice Vivo (J)*.

I. TRANSFORMER E ARQUITETURA

1. **Vaswani et al. — Attention Is All You Need (2017)**. O paper que mudou a IA moderna. Leitura inegociável.
2. **Devlin et al. — BERT (2018)**. Pré-treinamento bidirecional. Fundamento de embeddings modernos.
3. **Radford et al. — GPT (2018) e GPT-2 (2019)**. Pré-treinamento generativo, escala.
4. **Brown et al. — Language Models are Few-Shot Learners (GPT-3, 2020)**. Emergência de capacidade por escala.
5. **Touvron et al. — Llama 2 / Llama 3 (2023, 2024)**. Família open weights de referência.

II. CONTEXTO E ATENÇÃO

1. **Liu et al. — *Lost in the Middle* (2023).** Base empírica do Invariante 2.
 2. **Press et al. — *ALiBi: Train Short, Test Long* (2022).** Encoding posicional alternativo.
 3. **Su et al. — *RoPE* (2023).** Rotary position embeddings.
-

III. ALINHAMENTO E RLHF

1. **Christiano et al. — *Deep RL from Human Preferences* (2017).** Primeira formalização moderna do RLHF.
 2. **Ouyang et al. — *InstructGPT* (2022).** RLHF aplicado em produção.
 3. **Bai et al. — *Constitutional AI* (Anthropic, 2022).** RLAIFF e CAI.
 4. **Rafailov et al. — *DPO* (2023).** Substituição do PPO no mercado.
 5. **Hong et al. — *ORPO* (2024).** Variante recente.
 6. **Anthropic — *Collective Constitutional AI* (2023).** CAI com input público.
-

IV. EVALS E AVALIAÇÃO

1. **Liang et al. — *HELM* (Stanford CRFM, 2022).** Avaliação holística.
2. **Srivastava et al. — *BIG-bench* (2022).** Benchmark colaborativo.

3. **Zheng et al. — Judging LLM-as-a-Judge (2023).** Base de LLM-as-judge.
 4. **Liu et al. — G-Eval (2023).** Eval por LLM alinhada com humano.
 5. **Es et al. — RAGAS (2023).** Eval específica para RAG.
 6. **Mazeika et al. — HarmBench (2024).** Adversarial e red-teaming padronizados.
-

V. AGENTES E TOOL USE

1. **Yao et al. — ReAct (2022).** Padrão “raciocinar + agir” canônico.
 2. **Schick et al. — Toolformer (2023).** Modelos que aprendem a usar tools.
 3. **Wang et al. — Voyager (2023).** Agente em Minecraft, modelo de descoberta.
 4. **Anthropic — Building Effective Agents (2024).** Distinção workflow × agente.
-

VI. INTERPRETABILIDADE MECANICISTA

1. **Olah et al. — In-context Learning and Induction Heads (2022).** Circuitos identificados.
2. **Anthropic — Towards Monosemanticity (2023).** Sparse auto-encoders.
3. **Anthropic — Scaling Monosemanticity (2024).** Aplicação em Claude 3 Sonnet.

VII. SEGURANÇA E COMPORTAMENTO

1. **Perez et al. — *Discovering Language Model Behaviors with Model-Written Evals* (2022).** Auto-descoberta de comportamentos problemáticos.
 2. **Ganguli et al. — *Red Teaming Language Models* (Anthropic, 2022).** Metodologia de red-teaming.
 3. **Sharma et al. — *Towards Understanding Sycophancy* (2023).** Mecânica da bajulação.
 4. **Greshake et al. — *Prompt Injection in LLM-Integrated Applications* (2023).** Vetor de ataque dominante.
 5. **Bender et al. — *On the Dangers of Stochastic Parrots* (2021).** Crítica fundamentada.
-

VIII. RAG E RETRIEVAL

1. **Lewis et al. — *RAG: Retrieval-Augmented Generation* (2020).** Paper seminal.
 2. **Karpukhin et al. — *Dense Passage Retrieval (DPR)* (2020).** Retrieval moderno.
 3. **Reimers, Gurevych — *Sentence-BERT* (2019).** Embeddings para busca semântica.
-

COMO LER PAPERS DE IA

1. **Abstract + conclusão primeiro.** 60% dos papers basta isso.
2. **Para os 40% que valem mais, leia diagramas e tabelas.**
3. **Equações só onde a matemática realmente sustenta a tese.**
4. **Discussions e limitações** dizem mais que método em muitos casos.
5. **Para citação séria, ler integralmente.**

▣ [Apêndice E Leituras](#) · [Apêndice F Newsletters](#) · [Apêndice H Bibliografia](#)

APÊNDICE H — BIBLIOGRAFIA COMPLETA

Fontes primárias e secundárias citadas na obra

Bibliografia consolidada da obra. Para curadoria comentada, ver [Apêndice E \(Leituras\)](#), [Apêndice F \(Newsletters\)](#) e [Apêndice G \(Papers\)](#). Versões correntes de documentação técnica e regulação no [Apêndice Vivo \(J\)](#).

I. PAPERS SEMINAIS

Transformer e LLMs

- Vaswani, A. et al. *Attention Is All You Need* (2017)
- Devlin, J. et al. *BERT: Pre-training of Deep Bidirectional Transformers* (2018)
- Brown, T. et al. *Language Models are Few-Shot Learners* (GPT-3) (2020)
- Touvron, H. et al. *LLaMA 2: Open Foundation and Fine-Tuned Chat Models* (2023)
- Anthropic. *The Claude 3 Model Family* (2024)

Atenção e contexto

- Liu, N. F. et al. *Lost in the Middle: How Language Models Use Long Contexts* (2023)
- Press, O. et al. *Train Short, Test Long: Attention with Linear Biases (ALiBi)* (2022)
- Su, J. et al. *RoFormer: Enhanced Transformer with Rotary Position Embedding (RoPE)* (2023)

Alinhamento

- Christiano, P. et al. *Deep Reinforcement Learning from Human Preferences* (2017)
- Ouyang, L. et al. *Training language models to follow instructions with human feedback (InstructGPT)* (OpenAI, 2022)
- Bai, Y. et al. *Constitutional AI: Harmlessness from AI Feedback* (Anthropic, 2022)
- Anthropic. *Collective Constitutional AI* (2023)
- Rafailov, R. et al. *Direct Preference Optimization* (2023)
- Hong, J. et al. *ORPO: Monolithic Preference Optimization without Reference Model* (2024)
- Ethayarajh, K. et al. *KTO: Model Alignment as Prospect Theoretic Optimization* (2024)

Interpretabilidade

- Olah, C. et al. *In-context Learning and Induction Heads* (Anthropic, 2022)
- Anthropic. *Towards Monosemanticity* (2023)
- Anthropic. *Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet* (2024)

Evals

- Liang, P. et al. HELM: Holistic Evaluation of Language Models (Stanford CRFM, 2022-)
- Srivastava, A. et al. BIG-bench: Beyond the Imitation Game Benchmark (2022)
- Zheng, L. et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena (2023)
- Liu, Y. et al. G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment (2023)
- Es, S. et al. RAGAS: Automated Evaluation of Retrieval Augmented Generation (2023)
- Mazeika, M. et al. HarmBench: A Standardized Evaluation Framework for Automated Red Teaming and Robust Refusal (2024)
- Bowman, S. Evaluating LLMs is a minefield (palestra, 2023)

Agentes

- Yao, S. et al. ReAct: Synergizing Reasoning and Acting in Language Models (2022)
- Schick, T. et al. Toolformer: Language Models Can Teach Themselves to Use Tools (2023)
- Wang, G. et al. Voyager: An Open-Ended Embodied Agent with Large Language Models (2023)
- Anthropic. Building Effective Agents (2024)

RAG e retrieval

- Lewis, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks (2020)

- Karpukhin, V. et al. *Dense Passage Retrieval for Open-Domain Question Answering* (2020)
- Reimers, N., Gurevych, I. *Sentence-BERT* (2019)

Segurança e comportamento

- Perez, E. et al. *Discovering Language Model Behaviors with Model-Written Evaluations* (Anthropic, 2022)
- Ganguli, D. et al. *Red Teaming Language Models to Reduce Harms* (Anthropic, 2022)
- Sharma, M. et al. *Towards Understanding Sycophancy in Language Models* (Anthropic, 2023)
- Greshake, K. et al. *Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* (2023)
- Liu, Y. et al. *Prompt Injection attack against LLM-integrated Applications* (2023)
- Bender, E. et al. *On the Dangers of Stochastic Parrots* (2021)

Filosofia e fundamento

- Russell, S. *Human Compatible* (2019)
 - Christian, B. *The Alignment Problem* (2020)
 - Bommasani, R. et al. *On the Opportunities and Risks of Foundation Models* (Stanford CRFM, 2021)
-

II. LIVROS E REFERÊNCIAS DE FUNDO

- Russell, S. & Norvig, P. *Artificial Intelligence: A Modern Approach* (4^a ed., 2020)
- Bishop, C. & Bishop, H. *Deep Learning: Foundations and Concepts* (2024)
- Goodfellow, I., Bengio, Y., Courville, A. *Deep Learning* (2016)
- Murphy, K. *Probabilistic Machine Learning* (2 vols., 2022 e 2023)
- Engelbart, D. *Augmenting Human Intellect* (1962)
- Drucker, P. *The Effective Executive* (1966)
- Brooks, F. *The Mythical Man-Month* (1975/1995)
- Beyer, B. et al. *Site Reliability Engineering* (Google, 2016) e *The Site Reliability Workbook* (2018)
- Allspaw, J. & Robbins, J. *Web Operations* (2010)
- Doerr, J. *Measure What Matters* (2018)
- Kotter, J. *Leading Change* (1996)
- Davenport, T. *The AI Advantage* (2018)
- Schmidhuber, J. *Annotated History of Modern AI* (recente)

III. NORMAS, REGULAÇÃO, FRAMEWORKS PÚBLICOS

- NIST. *AI Risk Management Framework* (AI RMF 1.0) (2023)

- ISO/IEC 42001 – Information technology – Artificial intelligence – Management system (2023)
 - OECD AI Principles (2019, revisão 2024)
 - EU AI Act (Regulation 2024/1689)
 - Brasil – PL 2338/2023 (em tramitação no Senado Federal)
 - LGPD – Lei 13.709/2018 (Brasil)
 - ANPD – Guias e enunciados sobre IA (2023-2026, ver Apêndice Vivo)
 - Anthropic. *Responsible Scaling Policy* (2023, 2024)
-

IV. DOCUMENTAÇÃO TÉCNICA OFICIAL

- Anthropic Claude documentation
 - OpenAI documentation
 - Google AI Studio
 - Model Context Protocol specification
 - OpenTelemetry GenAI semantic conventions
 - Hugging Face Hub
-

V. RECURSOS PEDAGÓGICOS COMENTADOS

Curadoria comentada de cursos, newsletters e canais – ver [Apêndice E](#) e [Apêndice F](#).

VI. SOBRE ESTA OBRA

Inteligência Aumentada — Os Invariantes da IA (Livro 1) e **Inteligência Aumentada — Volume Vivo: Dominando Claude** (Livro 2). Autor: Fabio Garcia. Edição: 1ª. Ano: 2026. Plano editorial inclui Edição Aniversário em 5 anos.

Os 9 Invariantes da IA são sistema proprietário desta obra, sintetizando padrões observáveis em literatura técnica, em práticas operacionais e em incidentes documentados. As referências secundárias que mais influenciaram a formulação estão listadas no Cap 00M §00M.14.

▢ [Apêndice E Leituras](#) · [Apêndice F Newsletters](#) · [Apêndice G Papers obrigatórios](#) · [Apêndice Vivo \(J\)](#)

APÊNDICE I — ÍNDICE REMISSIVO

Termos, frameworks, Invariantes, casos — onde encontrar na obra

Índice em ordem alfabética. Cada termo aponta para capítulo(s) ou framework(s) onde é aprofundado. Para vocabulário definido, ver [Apêndice A — Glossário](#). Marcadores: ★ termo proprietário da obra; ◆ termo técnico canônico.

A

- **Accountable** (RACI) — Cap 42 §42.3.3, F6 GOV-INDELEGÁVEL
- **Adversarial set** ◆ — Cap 39 §39.3.2, F8 EVAL-PIRÂMIDE
- **Agente** ◆ — Cap 12 (conceitual), Cap 40 (operacional), F3 AGENTE-PROP
- **AI Council** — Cap 42 §42.3.4
- **Alignment** ★ — Cap 41
- **Apêndice Vivo** — Apêndice J (L2)
- **Artifacts (Claude)** — Cap 21 (L2)
- **Atenção (Q/K/V)** ◆ — Cap 02 §2.3.5 (boxe técnico)
- **AUP — Política de Uso Aceitável** — Cap 42 §42.3.5

- **Autonomia Proporcional ★** — Invariante 6, Cap 12, Cap 40, F3

B

- **Banco Solar (caso)** — EC1, Cap 00M §00M.5
- **Benchmark ♦** — Cap 15 §15.3.3, Apêndice Vivo
- **BPE** — Cap 03

C

- **Camada Dupla ★** — Invariante 3, Cap 01, F9 ROTA-DUPLA
- **Canário** — Cap 40 §40.3.3
- **Chain of Thought (CoT)** — Cap 10
- **Circuit breaker** — Cap 40 §40.3.5
- **Claude Code** — Cap 24 (L2)
- **Claude Web** — Cap 19 (L2)
- **Constitutional AI** — Cap 41 §41.3.2
- **Context Engineering** — Cap 11
- **Custo Composto ★** — Invariante 5, Cap 36, F7 COMPOSTO-3T

D

- **Datasets de prática** — Apêndice K, Repositório acompanhante
- **DECID-IA (F1)** — Frameworks/L1-F1
- **DPO (Direct Preference Optimization)** — Cap 41 §41.3.2

E

- **Embeddings** ♦ — Cap 05
- **Encaixe** ★ — Invariante 4, Cap 15, F2 ENCAIXE-5
- **Enterprise (Claude)** — Cap 30 (L2)
- **Evals** — Cap 39, F8 EVAL-PIRÂMIDE
- **EVAL-PIRÂMIDE (F8)** — Frameworks/L1-F8
- **Executivos (Claude para)** — Cap 34 (L2)
- **Extremidades** ★ — Invariante 2, Cap 04, F4 PROMPT-EXT

F

- **Faithfulness** — Cap 39, Apêndice A
- **Fine-tuning** ♦ — Cap 08, Trade-off T1, T6
- **Frameworks F1-F9** — Frameworks/

G

- **Gabaritos** — Apêndice K
- **Glossário** — Apêndice A
- **Golden set** ★ ♦ — Cap 39 §39.3.4, F8 EVAL-PIRÂMIDE
- **GOV-INDELEGÁVEL (F6)** — Frameworks/L1-F6
- **Governança de IA** — Cap 42, F6

H

- **Haiku, Sonnet, Opus** ♦ — Cap 18 (L2)

- **Helpful, Harmless, Honest** — Cap 41 §41.1

I

- **Interpretabilidade mecanicista** — Cap 41 §41.3.3
- **Invariantes da IA ★** — Cap 00M (Manifesto), Apêndice M (bolso)

J

- **Janela de contexto ♦** — Cap 04

K

- **Kill switch** — Cap 40 §40.3.6

L

- **LGPD art. 20** — Cap 42 §42.3.6, EC2
- **LLM-as-judge ★ ♦** — Cap 39 §39.3.5, F8
- **LLMOps** — Cap 40
- **Lost in the Middle ♦** — Cap 04, Inv. 2

M

- **Manifesto dos Invariantes** — Cap 00M, Apêndice M
- **Mapa Mental** — Apêndice B
- **MCP** — Cap 13 (conceitual), Cap 33 (L2), F5 MCP-COBERTURA

- **MCP-COBERTURA (F5)** — Frameworks/L1-F5
- **Memória ♦** — Cap 07
- **Métrica.io (caso)** — EC4
- **MTTR** — Cap 40 §40.3.4

O

- **Open source (modelos)** — Cap 16, Trade-off T3
- **OpenTelemetry GenAI** — Cap 40 §40.3.1
- **Operador ★** — Invariante 9, Cap 34 (L2), F1
- **Over-refusal** — Cap 41 §41.3.4

P

- **Plausibilidade ★** — Invariante 1, Cap 41
- **Pólice.io (caso)** — Cap 40 §40.6
- **Postmortem sem culpa** — Cap 42 §42.3.7
- **Projects (Claude)** — Cap 20 (L2)
- **Prompt** — Cap 09, Apêndice L, F4 PROMPT-EXT
- **PROMPT-EXT (F4)** — Frameworks/L1-F4
- **Prompt injection** — Cap 40 §40.3.6

Q

- **Q/K/V (Query Key Value)** — Cap 02 §2.3.5

R

- **RACI** — Cap 42 §42.3.3, F6
- **RAG** ♦ — Cap 06, Trade-off T1
- **RedeCasa (caso)** — EC2
- **Refusal training** — Cap 41 §41.3.4
- **Repositório** **acompanhante**
— `/_repositorio-acompanhante/`
- **Research (Claude)** — Cap 22 (L2)
- **Responsabilidade Indelegável** ★ — Invariante 8, Cap 42, F6
- **Reward hacking** — Cap 41 §41.3.2
- **RLAIF** — Cap 41 §41.3.2
- **RLHF** — Cap 41 §41.3.2
- **Roadmap pessoal** — Cap 44, Apêndice C
- **Rollback** — Cap 40 §40.3.4
- **ROTA-DUPLA (F9)** — Frameworks/L1-F9

S

- **Sandbagging** — Cap 41 §41.3.4
- **SEV-1 a SEV-4** — Cap 40 §40.3.7, Cap 42 §42.3.7
- **SFT (Supervised Fine-Tuning)** — Cap 41 §41.3.2
- **Shadow mode** — Cap 40 §40.3.3
- **Skills (Claude)** — Cap 31 (L2)
- **Span × Trace × Session** — Cap 40 §40.3.1
- **Sparse Autoencoders** — Cap 41 §41.3.3
- **Subagents** — Cap 32 (L2)

- **Sycophancy** — Cap 41 §41.3.2, Cap 39

T

- **Team (Claude)** — Cap 29 (L2)
- **Termômetro** ★ — Invariante 7, Cap 39, F8
- **Tokens** ♦ — Cap 03
- **Tokenizer** ♦ — Cap 03 §3.3.1
- **Trade-offs canônicos** — Cap 43
- **Tracing** — Cap 40 §40.3.1
- **Transformer** ♦ — Cap 02

V

- **Validação UAU** ★ — Cada capítulo + Apêndice A
- **Versionamento** — Cap 40 §40.3.2
- **Vianna Castro Almeida (caso)** — EC3
- **Vibe-eval** — Cap 39 §39.3.9 (anti-padrão)

Y, W

- **Workflow determinístico** — Cap 43 §43.3 (T2)

▢ [Apêndice A Glossário](#) · [Apêndice B Mapa mental](#) · [Apêndice M Manifesto de bolso](#)

APÊNDICE K — GABARITOS COMENTADOS

Soluções estruturadas para exercícios e projetos da obra

Este apêndice oferece **estruturas de resposta** para os exercícios práticos e projetos dos capítulos. Não são respostas únicas; são gabaritos que mostram **o método de pensar** que cada exercício pretende ativar. Use como referência para autoavaliação, nunca como atalho para pular o esforço.

COMO USAR ESTE APÊNDICE

1. **Faça o exercício primeiro.** Sem isso, o gabarito vira leitura passiva.
2. **Compare estrutura, não conteúdo.** O gabarito mostra “como pensar”, não “o que pensar”.
3. **Customize ao seu domínio.** Cada gabarito é genérico; sua resposta deve ser específica.
4. **Reverifique após 90 dias.** Gabaritos evoluem com o leitor.

CAP 00M — MANIFESTO DOS INVARIANTES

Exercício 1 — Diagnóstico do time

Estrutura esperada: lista de 9 violações típicas (uma por Invariante) com exemplo específico do time. Identificar os 3 mais críticos com sinal (ex: “regressão silenciosa não detectada nos últimos 6 meses” para Inv. 7).

Exercício 2 — Auditoria de decisões

Estrutura esperada: tabela com 3 decisões × 9 Invariantes; marcar respeitado/violado; descrever o que mudaria.

Projeto — Cartaz dos Invariantes da empresa

Critério de qualidade: uma página A3, com violação típica adaptada à linguagem do seu setor. Outro executivo lê e reconhece os 9 Invariantes pela sua versão sem ambiguidade.

CAP 02 — COMO MODELOS FUNCIONAM

Projeto — Plano para apresentar o transformer à diretoria

Estrutura: Slide 1 (analogia do estagiário que leu tudo); Slide 2 (predição de próximo token); Slide 3 (Q/K/V em alto nível, sem fórmula); Slide 4 (consequência prática — Plausibilidade); Slide 5 (Camada Dupla aplicada à diretoria).

CAP 03 — TOKENS

Exercício 1 — Auditoria de tokens da operação

Estrutura: levantamento de input/output médio por feature; cálculo da fração que é prompt vs resposta; identificação do maior consumidor de tokens.

Projeto — Plano de economia

Estrutura: aplicar F7 COMPOSTO-3T; identificar tier dominante; identificar redundância; plano em 30 dias.

CAP 06 — RAG

Projeto — Caderno de RAG do produto

Estrutura: definição de “resposta certa” → estratégia de chunking → modelo de embedding → reranking → política de top-k → eval de faithfulness.

CAP 09 — ENGENHARIA DE PROMPT

Projeto — Aplicar F4 PROMPT-EXT em 5 prompts

Estrutura: para cada prompt, reescrever nos 5 blocos canônicos. Antes/depois com justificativa por bloco.

CAP 39 — EVALS

Exercício 1 — Classificação de falhas

Estrutura: para cada falha listada, marcar qual camada da pirâmide a teria capturado; identificar a camada mais frágil hoje.

Projeto — Caderno de Evals v1

Critério de qualidade: outro engenheiro lê e roda eval contra mudança nova sem perguntar mais que 3 coisas. Inclui golden set 30-50 itens, LLM-as-judge calibrado com correlação $\geq 0,7$ contra humano, adversarial 20+ casos, política de bloqueio em CI.

CAP 40 — LLMOPS

Exercício 1 — Diagnóstico dos 7 pilares

Estrutura: matriz 7×5 (pilar × maturidade 0-4); identificar 2 mais frágeis; plano de 60 dias.

Projeto — Caderno de LLMOps v1

Critério de qualidade: outro engenheiro responde sem perguntar qualquer das 7 perguntas executivas (§40.10).

CAP 41 — ALIGNMENT

Exercício 3 — Mini-constituição corporativa

Estrutura: 7 princípios em pt-BR, cada um em uma frase, sem jargão. Submetido a par sênior para revisão.

Projeto — Caderno de Alignment Operacional

Critério de qualidade: outro engenheiro sênior responde “como nosso sistema lida com pedido de conselho médico não-supervisionado?” sem perguntar.

CAP 42 — GOVERNANÇA

Projeto — Caderno de Governança v1

Critério de qualidade: outro executivo responde sem ambiguidade: “quem é o Accountable por X?”, “qual a maturidade do controle Y?”, “quando é o próximo simulado?”.

CAP 43 — TRADE-OFFS

Projeto — Cardápio de Trade-offs do produto

Critério de qualidade: outro executivo defende a arquitetura em reunião externa (cliente, conselho, auditor) sem perguntar.

CAP 44 — ROADMAP PESSOAL

Projeto — Apresentação à diretoria

Critério de qualidade: diretoria aprova o roadmap em uma reunião, com mandato formal sobre IA.

▣ [Cap 00M](#) · [Apêndice C Roadmaps](#) · [Apêndice L Biblioteca de prompts](#)

APÊNDICE L — BIBLIOTECA DE PROMPTS TESTADOS

Espelho conceitual do `/prompts` no repositório acompanhante

Cada prompt aqui segue a estrutura **F4 PROMPT-EXT** (5 blocos posicionais) e é categorizado por caso de uso. A versão rodável vive no [repositório acompanhante](#). Esta lista é a referência conceitual; a implementação rodável e atualizada vive fora do livro.

ESTRUTURA CANÔNICA DE TODO PROMPT NA BIBLIOTECA

```
[BLOCO 1 — PERSONA E MISSÃO]
[BLOCO 2 — CONSTITUIÇÃO (regras invioláveis)]
[BLOCO 3 — CONTEXTO]
[BLOCO 4 — INSTRUÇÃO OPERACIONAL + FORMATO]
[BLOCO 5 — PERGUNTA VIVA]
```

CATEGORIAS

1. Análise jurídica e DD em M&A (EC3 Vianna Castro)

Prompt	Função	Eval mínimo
extrair-change-of-control	Identifica cláusula com citação literal	Golden set 40 contratos + honestidade de citação
red-flag-mac	Marca Material Adverse Change	Golden set + adversarial de redação ambígua
sumario-categoria-clausula	Sumário executivo por categoria	LLM-as-judge calibrado
comparar-clausula-padrao	Compara cláusula contra padrão da banca	Golden set por tipo de operação

2. Escrita executiva

Prompt	Função	Eval mínimo
memo-para-board	Memo de 1 página com decisão pedida	Golden set 30 memos + voz padrão
sumario-executivo-relatorio	Sumário de 5 bullets de relatório técnico	LLM-as-judge calibrado
q-a-para-diretoria	Roteiro de antecipação de objeções	Adversarial de pergunta hostil

3. Classificação estruturada (EC1 Banco Solar)

Prompt	Função	Eval mínimo
classificar-tier-ticket	Classifica ticket em tier 1-4	Golden set 600 tickets
roteamento-por-intent	Decide agente apropriado por intent	F1 ponderada por classe
escalonamento-para-humano	Decide se escalar	Adversarial sycophancy bancário

4. Extração de campos

Prompt	Função	Eval mínimo
extrair-campos-curriculo	Extrai sem inferir atributo protegido	Golden + adversarial pareado (EC2)
extrair-numeros-relatorio	Extrai com faithfulness numérica	LLM-as-judge calibrado (EC6 Atlas)
extrair-stakeholders	Mapa de stakeholders B2B (EC5 EnterTech)	Golden set 50 briefs

5. Agentes supervisionados

Prompt	Função	Eval mínimo
agente-cota-cao-seguro	Cotação assistida 7 seguradoras (Pólice.io)	Tracing + circuit breaker + eval de loop
agente-supor-te-tier-1	Atendimento tier 1 (EC1)	Golden + adversarial sycophancy
agente-prospect-re-search	Pesquisa de prospect (EC5)	Honestidade de fonte

6. RAG e síntese (EC4 Métrica.io)

Prompt	Função	Eval mínimo
rag-documentacao-saas	Resposta de docs com citação	Faithfulness + context precision
explicar-re-sultado-query	Explicação de gráfico/tabela	LLM-as-judge calibrado para precisão numérica
sugerir-insight-dados	Sugestão de insight baseado em dados	Adversarial: ausência de dados → “não tenho como afirmar”

REGRAS DE USO DA BIBLIOTECA

1. **Não copie cegamente.** Cada prompt é instância de F4; entenda o porquê antes de adaptar.

2. **Customize ao seu domínio.** Os prompts são genéricos; sua aplicação demanda específico.
 3. **Inicie com golden set próprio.** Não use o golden set de exemplo em produção; é referência.
 4. **Reverifique após mudança de modelo.** Prompt calibrado para X pode regredir em Y.
 5. **Mantenha versionado.** Trate prompts como código (LLMOps Pilar 2).
-

ANTI-PADRÕES NA CONSTRUÇÃO DE PROMPT

Anti-padrão	Por que mata	Antídoto
Regra crítica no meio do prompt	Inv. 2 — atenção decai no centro	F4: regra na Constituição (logo após per-sona)
Pergunta antes do con-texto	Modelo responde sem ver o contexto	F4: Pergunta viva é última
Constituição ambígua	Modelo interpreta livre-mente	Bullets curtos, instruções impe-rativas
Sem reiteração no bloco 4	Em prompts longos, re-gra do topo enfraquece	Reiterar o crítico antes da pergun-ta
Sem sanitização do in-put	Prompt injection sobres-creve a constituição	Sanitizar antes do bloco 5
Prompt como string no código	Sem rastreabilidade	Tratar como ar-tefato versiona-do

▣ Cap 09 Engenharia de Prompt · Cap 11 Context Engineering · F4 PROMPT-EXT · Repositório acompanhante

APÊNDICE M — MANIFESTO DOS INVARIANTES DA IA

Versão de bolso · página única
destacável

Imprima. Cole na parede. Distribua ao time. Leve para a próxima decisão de IA.

OS 9 INVARIANTES

1 — PLAUSIBILIDADE

“O modelo entrega o plausível, não o verdadeiro — e os dois coincidem, até a hora em que não.” *Mecânica:* LLM é motor de plausibilidade; calibração de confiança é trabalho do operador, proporcional ao custo do erro. *Violação típica:* aceitar número jurídico ou financeiro porque “soou certo”. ▢ Cap 02 · Cap 41 · válido enquanto a arquitetura generativa atual dominar

2 — EXTREMIDADES

“O meio do contexto é onde a informação vai morrer.” *Mecânica:* atenção alta nas pontas, diluída no centro; densidade de relevância vence volume. *Violação típica:* enterrar a regra crítica no parágrafo 40 do prompt. □ Cap 04 · F4 PROMPT-EXT · válido enquanto a arquitetura transformer atual dominar

3 — CAMADA DUPLA

“Decore o padrão, consulte o número.” *Mecânica:* o que muda em semanas vive em apêndice datado; o que dura por anos vive na cabeça. *Violação típica:* memorizar “modelo X lidera benchmark Y” e ficar obsoleto no próximo release. □ Cap 01 · Apêndice Vivo · F9 ROTA-DUPLA

4 — ENCAIXE

“Escolha pelo padrão da tarefa, nunca pela versão da moda.” *Mecânica:* decide-se modelo por eixo (código, mate, multimodal, contexto longo, custo), não pelo lançamento da semana. *Violação típica:* migrar o stack para o release recente sem teste cego na carga real. □ Cap 15 · F2 ENCAIXE-5

5 — CUSTO COMPOSTO

“Trivial é o preço do token; o que quebra o orçamento é quantas vezes você o paga.” *Mecânica:* custo = tokens × chamadas × tier × redundância; alavancas são arquiteturais. *Violação típica:* otimizar prompt enquanto um loop de agente dispara 40 chamadas redundantes. □ Cap 36 · F7 COMPOSTO-3T

6 — AUTONOMIA PROPORCIONAL

“Só dê ao agente a autonomia que você consegue medir e desfazer.” *Mecânica:* nível de agência = função da capacidade de rastrear e reverter. *Violação típica:* agente com escrita em produção sem tracing nem kill switch. □ Cap 12 · Cap 40 · F3 AGENTE-PROP

7 — TERMÔMETRO

“IA sem eval é fé, não engenharia.” *Mecânica:* nenhum sistema entra em produção sem detecção de regressão; prompt sem golden set é opinião. *Violação típica:* trocar prompt “porque ficou melhor” sem dataset que prove que não piorou. □ Cap 39 · F8 EVAL-PIRÂMIDE

8 — RESPONSABILIDADE INDELEGÁVEL

“A IA executa; a responsabilidade tem sempre um nome humano.” *Mecânica:* toda saída em produção tem dono, controle de acesso, trilha de auditoria, caminho de reversão. *Violação típica:* “foi a IA que decidiu” como desculpa para decisão que ninguém assume. □ Cap 42 · F6 GOV-INDELEGÁVEL

9 — OPERADOR

“A IA multiplica competência e incompetência pelo mesmo fator.” *Mecânica:* ganho vem do operador que sabe pedir, rejeitar e validar. *Violação típica:* esperar que a IA cubra a falta de critério de quem a opera. □ Cap 34 (L2) · Cap 44 · F1 DECID-IA

A FRASE-ÂNCORA

Modelos passam. Método fica.

COMO USAR

Situação	Pergunte-se
Vou escolher um modelo	F2 (Inv. 4): qual o encaixe por eixo de tarefa?
Vou subir um agente	F3 (Inv. 6): tenho tracing e rollback proporcionais?
Vou trocar um prompt em produção	F8 (Inv. 7): rodou contra o golden set ?
Vou apresentar a iniciativa à diretoria	F1 (Inv. 9) e F6 (Inv. 8): há dono e há decisão estruturada?
Vou cortar custo de IA	F7 (Inv. 5): mexi nas 3 alavancas arquiteturais ?
Vou citar um benchmark	(Inv. 3): conferi o Apêndice Vivo com data e fonte?

NOTA DE HONESTIDADE

Os Invariantes 1 (Plausibilidade) e 2 (Extremidades) dependem da arquitetura generativa atual. Arquiteturas futuras podem mudar a mecânica; os outros sete são princípios de prática e julgamento, independentes de arquitetura.

ATRIBUIÇÃO

Os 9 Invariantes da IA — sistema proprietário de *Inteligência Aumentada* (Fabio Garcia, 2026). Distribuição livre com atribuição. Versão original em github.com/fabiogarcia/inteligencia-aumentada (URL ilustrativa — confirmar).

▣ **Aprofundamento:** Cap 00M — Manifesto dos Invariantes