

Apêndice G — Papers Fundamentais

Curadoria de papers que sustentam o estado da arte conceitual em IA generativa

Curadoria por categoria. Cada entrada com uma ou duas linhas explicando por que ler.

I. Transformer e arquitetura

1. **Vaswani et al. — *Attention Is All You Need* (Google, 2017).** O paper que mudou a IA moderna. Leitura inegociável.
2. **Devlin et al. — *BERT* (Google, 2018).** Pré-treinamento bidirecional. Fundamento de embeddings modernos.
3. **Radford et al. — *GPT* (OpenAI, 2018) e *GPT-2* (OpenAI, 2019).** Pré-treinamento generativo e ganho por escala.
4. **Brown et al. — *Language Models are Few-Shot Learners* (GPT-3, OpenAI, 2020).** Emergência de capacidade por escala.
5. **Touvron et al. — *Llama* (Meta, 2023) e *Llama 2 / Llama 3* (Meta, 2023-2024).** Família open weights de referência.
6. **Jiang et al. — *Mistral 7B* (Mistral, 2023) e *Mixtral of Experts* (Mistral, 2024).** Mistura de especialistas em open weights.
7. **DeepSeek-AI — *DeepSeek-V3* e *DeepSeek-R1* (DeepSeek, 2024-2025).** Arquitetura MoE e raciocínio em peso aberto.

8. **Hoffmann et al. — *Training Compute-Optimal Large Language Models* (Chinchilla, DeepMind, 2022).** Leis de escala revisadas.
 9. **Anil et al. — *PaLM 2 Technical Report* (Google, 2023) e *Gemini Technical Report* (Google DeepMind, 2023-2024).** Família de modelos multimodais.
 10. **Anthropic — *The Claude 3 Model Family* (2024).** Documentação de família comercial.
-

II. Contexto e atenção

1. **Liu et al. — *Lost in the Middle* (Stanford, 2023).** Base empírica do princípio das extremidades.
 2. **Press et al. — *ALiBi: Train Short, Test Long* (Meta, 2022).** Encoding posicional alternativo.
 3. **Su et al. — *RoFormer (RoPE)* (2023).** Rotary position embeddings.
 4. **Dao et al. — *FlashAttention e FlashAttention-2* (Stanford, 2022-2023).** Eficiência de atenção em GPUs.
-

III. Alinhamento, RLHF e preferência

1. **Christiano et al. — *Deep RL from Human Preferences* (OpenAI / DeepMind, 2017).** Primeira formalização moderna do RLHF.
2. **Ouyang et al. — *InstructGPT* (OpenAI, 2022).** RLHF aplicado em produção.
3. **Bai et al. — *Constitutional AI* (Anthropic, 2022).** RLAIIF e CAI.
4. **Anthropic — *Collective Constitutional AI* (2023).** CAI com input público.
5. **Rafailov et al. — *Direct Preference Optimization* (Stanford, 2023).** Substituição do PPO no mercado.
6. **Hong et al. — *ORPO* (2024).** Variante sem modelo de referência.
7. **Ethayarajh et al. — *KTO* (2024).** Alinhamento por teoria do prospecto.

IV. Evals e avaliação

1. Liang et al. — *HELM* (Stanford CRFM, 2022). Avaliação holística.
 2. Srivastava et al. — *BIG-bench* (Google e colaboradores, 2022). Benchmark colaborativo.
 3. Hendrycks et al. — *Measuring Massive Multitask Language Understanding* (MMLU, 2020). Benchmark de referência amplo.
 4. Zheng et al. — *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena* (LMSYS, 2023). Base de LLM-as-judge.
 5. Liu et al. — *G-Eval* (Microsoft, 2023). Eval por LLM alinhada com humano.
 6. Es et al. — *RAGAS* (Exploding Gradients, 2023). Eval específica para RAG.
 7. Mazeika et al. — *HarmBench* (CAIS, 2024). Adversarial e red-teaming padronizados.
-

V. Agentes e tool use

1. Yao et al. — *ReAct* (Princeton e Google, 2022). Padrão de raciocinar e agir.
 2. Schick et al. — *Toolformer* (Meta, 2023). Modelos que aprendem a usar ferramentas.
 3. Wang et al. — *Voyager* (NVIDIA, 2023). Agente em Minecraft como modelo de descoberta.
 4. Anthropic — *Building Effective Agents* (2024). Distinção entre workflow e agente.
 5. Significant Gravitas — *AutoGPT technical reports* (2023). Marco de agentes abertos.
-

VI. Interpretabilidade mecanicista

1. Olah et al. — *In-context Learning and Induction Heads* (Anthropic, 2022). Circuitos identificados.

2. Anthropic — *Towards Monosemanticity (2023) e Scaling Monosemanticity (2024)*. Sparse autoencoders aplicados a modelos comerciais.
 3. Nanda et al. — *Progress measures for grokking via mechanistic interpretability (DeepMind, 2023)*. Caso paradigmático de mech interp.
-

VII. Segurança e comportamento

1. Perez et al. — *Discovering Language Model Behaviors with Model-Written Evals (Anthropic, 2022)*. Auto-descoberta de comportamentos problemáticos.
 2. Ganguli et al. — *Red Teaming Language Models (Anthropic, 2022)*. Metodologia de red-teaming.
 3. Sharma et al. — *Towards Understanding Sycophancy (Anthropic, 2023)*. Mecânica da bajulação.
 4. Greshake et al. — *Indirect Prompt Injection in LLM-Integrated Applications (2023)*. Vetor de ataque dominante.
 5. Bender et al. — *On the Dangers of Stochastic Parrots (Washington, 2021)*. Crítica fundamentada.
 6. Weidinger et al. — *Taxonomy of Risks posed by Language Models (DeepMind, 2022)*. Mapa estruturado de riscos.
-

VIII. RAG e retrieval

1. Lewis et al. — *Retrieval-Augmented Generation (Meta e UCL, 2020)*. Paper seminal.
2. Karpukhin et al. — *Dense Passage Retrieval (Meta, 2020)*. Retrieval moderno.
3. Reimers, Gurevych — *Sentence-BERT (UKP TU Darmstadt, 2019)*. Embeddings para busca semântica.
4. Izacard et al. — *Atlas: Few-shot Learning with Retrieval Augmented Language Models (Meta, 2022)*. RAG com retrieval profundo.

Como ler papers de IA

1. Abstract e conclusão primeiro. Em sessenta por cento dos casos, isso basta.
2. Para os quarenta por cento que valem mais, leia diagramas e tabelas.
3. Equações apenas onde a matemática realmente sustenta a tese.
4. Discussões e limitações dizem mais que método em muitos casos.
5. Para citação séria, leia integralmente.

Apêndice H — Bibliografia Completa

Fontes primárias e secundárias citadas na obra

Bibliografia consolidada da obra. Para curadoria comentada, ver os apêndices de Leituras, Newsletters e Papers.

I. Papers seminais

Transformer e LLMs

- Vaswani, A. et al. *Attention Is All You Need* (Google, 2017)
- Devlin, J. et al. *BERT: Pre-training of Deep Bidirectional Transformers* (Google, 2018)
- Radford, A. et al. *Language Models are Unsupervised Multitask Learners* (GPT-2, OpenAI, 2019)
- Brown, T. et al. *Language Models are Few-Shot Learners* (GPT-3, OpenAI, 2020)
- Hoffmann, J. et al. *Training Compute-Optimal Large Language Models* (Chinchilla, DeepMind, 2022)
- Touvron, H. et al. *LLaMA 2: Open Foundation and Fine-Tuned Chat Models* (Meta, 2023)
- AI@Meta. *Llama 3 Model Card* (Meta, 2024)
- Jiang, A. et al. *Mistral 7B e Mixtral of Experts* (Mistral, 2023-2024)
- Anil, R. et al. *PaLM 2 Technical Report* (Google, 2023)

- Google DeepMind. *Gemini: A Family of Highly Capable Multimodal Models* (2023-2024)
- DeepSeek-AI. *DeepSeek-V3 Technical Report e DeepSeek-R1* (2024-2025)
- Anthropic. *The Claude 3 Model Family* (2024)

Atenção e contexto

- Liu, N. F. et al. *Lost in the Middle: How Language Models Use Long Contexts* (Stanford, 2023)
- Press, O. et al. *Train Short, Test Long: Attention with Linear Biases (ALiBi)* (Meta, 2022)
- Su, J. et al. *RoFormer: Enhanced Transformer with Rotary Position Embedding (RoPE)* (2023)
- Dao, T. et al. *FlashAttention e FlashAttention-2* (Stanford, 2022-2023)

Alinhamento

- Christiano, P. et al. *Deep Reinforcement Learning from Human Preferences* (OpenAI / DeepMind, 2017)
- Ouyang, L. et al. *Training language models to follow instructions with human feedback (InstructGPT)* (OpenAI, 2022)
- Bai, Y. et al. *Constitutional AI: Harmlessness from AI Feedback* (Anthropic, 2022)
- Anthropic. *Collective Constitutional AI* (2023)
- Rafailov, R. et al. *Direct Preference Optimization* (Stanford, 2023)
- Hong, J. et al. *ORPO: Monolithic Preference Optimization without Reference Model* (2024)
- Ethayarajh, K. et al. *KTO: Model Alignment as Prospect Theoretic Optimization* (2024)

Interpretabilidade

- Olah, C. et al. *In-context Learning and Induction Heads* (Anthropic, 2022)
- Nanda, N. et al. *Progress measures for grokking via mechanistic interpretability* (DeepMind, 2023)
- Anthropic. *Towards Monosemanticity* (2023)
- Anthropic. *Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet* (2024)

Evals

- Hendrycks, D. et al. *Measuring Massive Multitask Language Understanding (MMLU)* (2020)
- Liang, P. et al. *HELM: Holistic Evaluation of Language Models* (Stanford CRFM, 2022-)
- Srivastava, A. et al. *BIG-bench: Beyond the Imitation Game Benchmark* (Google e colaboradores, 2022)
- Zheng, L. et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena* (LMSYS, 2023)
- Liu, Y. et al. *G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment* (Microsoft, 2023)
- Es, S. et al. *RAGAS: Automated Evaluation of Retrieval Augmented Generation* (2023)
- Mazeika, M. et al. *HarmBench: A Standardized Evaluation Framework for Automated Red Teaming and Robust Refusal* (CAIS, 2024)
- Narayanan, A. & Kapoor, S. *Evaluating LLMs is a minefield* (Princeton, 2023)

Agentes

- Yao, S. et al. *ReAct: Synergizing Reasoning and Acting in Language Models* (Princeton e Google, 2022)
- Schick, T. et al. *Toolformer: Language Models Can Teach Themselves to Use Tools* (Meta, 2023)
- Wang, G. et al. *Voyager: An Open-Ended Embodied Agent with Large Language Models* (NVIDIA, 2023)
- Anthropic. *Building Effective Agents* (2024)

RAG e retrieval

- Lewis, P. et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks* (Meta e UCL, 2020)
- Karpukhin, V. et al. *Dense Passage Retrieval for Open-Domain Question Answering* (Meta, 2020)
- Reimers, N., Gurevych, I. *Sentence-BERT* (UKP TU Darmstadt, 2019)
- Izacard, G. et al. *Atlas: Few-shot Learning with Retrieval Augmented Language Models* (Meta, 2022)

Segurança e comportamento

- Perez, E. et al. *Discovering Language Model Behaviors with Model-Written Evaluations* (Anthropic, 2022)
- Ganguli, D. et al. *Red Teaming Language Models to Reduce Harms* (Anthropic, 2022)
- Sharma, M. et al. *Towards Understanding Sycophancy in Language Models* (Anthropic, 2023)
- Weidinger, L. et al. *Taxonomy of Risks posed by Language Models* (DeepMind, 2022)
- Greshake, K. et al. *Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection* (2023)
- Liu, Y. et al. *Prompt Injection attack against LLM-integrated Applications* (2023)
- Bender, E. et al. *On the Dangers of Stochastic Parrots* (Washington, 2021)

Filosofia e fundamento

- Russell, S. *Human Compatible* (2019)
- Christian, B. *The Alignment Problem* (2020)
- Bommasani, R. et al. *On the Opportunities and Risks of Foundation Models* (Stanford CRFM, 2021)

II. Livros e referências de fundo

- Russell, S. & Norvig, P. *Artificial Intelligence: A Modern Approach* (4ª ed., 2020)
- Bishop, C. & Bishop, H. *Deep Learning: Foundations and Concepts* (2024)
- Goodfellow, I., Bengio, Y., Courville, A. *Deep Learning* (2016)
- Murphy, K. *Probabilistic Machine Learning* (2 vols., 2022 e 2023)
- Engelbart, D. *Augmenting Human Intellect* (1962)
- Drucker, P. *The Effective Executive* (1966)
- Brooks, F. *The Mythical Man-Month* (1975/1995)
- Beyer, B. et al. *Site Reliability Engineering* (Google, 2016) e *The Site Reliability Workbook* (2018)

- Allspaw, J. & Robbins, J. *Web Operations* (2010)
 - Doerr, J. *Measure What Matters* (2018)
 - Kotter, J. *Leading Change* (1996)
 - Davenport, T. *The AI Advantage* (2018)
 - Schmidhuber, J. *Annotated History of Modern AI* (recente)
-

III. Normas, regulação e frameworks públicos

- NIST. *AI Risk Management Framework (AI RMF 1.0)* (2023)
 - ISO/IEC 42001 — *Information technology — Artificial intelligence — Management system* (2023)
 - OECD AI Principles (2019, revisão 2024)
 - EU AI Act (Regulation 2024/1689)
 - Brasil — PL 2338/2023 (em tramitação no Senado Federal)
 - LGPD — Lei 13.709/2018 (Brasil)
 - ANPD — Guias e enunciados sobre IA
 - Anthropic. *Responsible Scaling Policy* (2023, 2024)
 - OpenAI. *Preparedness Framework* (2023, 2024)
 - Google DeepMind. *Frontier Safety Framework* (2024)
-

IV. Documentação técnica oficial

- [OpenAI documentation](#)
- [Anthropic Claude documentation](#)
- [Google AI for Developers](#)
- [Meta Llama documentation](#)
- [Hugging Face Hub](#) e [Transformers library](#)
- [Model Context Protocol specification](#)
- [OpenTelemetry GenAI semantic conventions](#)

V. Recursos pedagógicos comentados

Curadoria comentada de cursos, newsletters e canais nos apêndices anteriores.

VI. Sobre esta obra

Inteligência Aumentada — Os Nove Princípios Permanentes (Livro 1). Autor: Fabio Garcia. Edição: 1ª. Ano: 2026.

Os Nove Princípios sintetizam padrões observáveis em literatura técnica, em práticas operacionais e em incidentes documentados. As referências secundárias que mais influenciaram a formulação estão listadas na introdução da obra.

Apêndice I — Índice Remissivo

Termos, métodos, princípios e casos — onde encontrar na obra

Índice em ordem alfabética. Cada termo aponta para o capítulo onde é aprofundado. Para vocabulário definido, ver o Apêndice A. Marcadores: ★ termo proprietário da obra; ◆ termo técnico canônico.

A

- **Accountable (RACI)** — capítulo sobre Governança
- **Adversarial set** ◆ — capítulo sobre Evals; Pirâmide da Avaliação
- **Agente** ◆ — capítulo conceitual sobre Agentes; capítulo sobre LLMOps; Escala de Propriedade do Agente
- **AI Council** — capítulo sobre Governança
- **Alignment** ★ — capítulo sobre Alinhamento
- **Atenção (Q/K/V)** ◆ — capítulo sobre Como modelos funcionam
- **AUP — Política de Uso Aceitável** — capítulo sobre Governança
- **Autonomia Proporcional** ★ — Princípio 6; capítulo sobre Agentes; capítulo sobre LLMOps; Escala de Propriedade do Agente

B

- **Banco Solar (caso)** — Engenharia de Prompt Estendida; Manifesto dos Princípios
- **Benchmark ♦** — capítulo sobre Comparação de modelos
- **BPE** — capítulo sobre Tokens

C

- **Camada Dupla ★** — Princípio 3; capítulo O que é IA; Rota Dupla de Adoção
- **Canário** — capítulo sobre LLMOps
- **Chain of Thought (CoT)** — capítulo sobre Chain of Thought
- **Circuit breaker** — capítulo sobre LLMOps
- **Constitutional AI** — capítulo sobre Alinhamento
- **Context Engineering** — capítulo sobre Context Engineering
- **Custo Composto ★** — Princípio 5; capítulo sobre Economia de tokens; Custo Composto em Três Tempos

D

- **Datasets de prática** — Apêndice K
- **Método de Decisão para Adotar IA** — método derivado do Princípio 9
- **DPO (Direct Preference Optimization)** — capítulo sobre Alinhamento

E

- **Embeddings ♦** — capítulo sobre Embeddings
- **Encaixe ★** — Princípio 4; capítulo sobre Comparação de modelos; Diagnóstico de Encaixe entre Tarefa e Modelo
- **Evals** — capítulo sobre Evals; Pirâmide da Avaliação
- **Pirâmide da Avaliação** — método derivado do Princípio 7
- **Extremidades ★** — Princípio 2; capítulo sobre Janela de contexto; Engenharia de Prompt Estendida

F

- **Faithfulness** — capítulo sobre Evals; Apêndice A

- **Fine-tuning** ♦ — capítulo sobre Fine-tuning; trade-offs canônicos

G

- **Gabaritos** — Apêndice K
- **Glossário** — Apêndice A
- **Golden set** ★ ♦ — capítulo sobre Evals; Pirâmide da Avaliação
- **Governança Indelegável** — método derivado do Princípio 8
- **Governança de IA** — capítulo sobre Governança

H

- **Helpful, Harmless, Honest** — capítulo sobre Alinhamento

I

- **Interpretabilidade mecanicista** — capítulo sobre Interpretabilidade mecanicista
- **Os Nove Princípios** ★ — Introdução; Apêndice M

J

- **Janela de contexto** ♦ — capítulo sobre Janela de contexto

K

- **Kill switch** — capítulo sobre LLMOps

L

- **LGPD art. 20** — capítulo sobre Governança
- **LLM-as-judge** ★ ♦ — capítulo sobre Evals; Pirâmide da Avaliação
- **LLMOps** — capítulo sobre LLMOps
- **Lost in the Middle** ♦ — capítulo sobre Janela de contexto; Princípio 2

M

- **Manifesto dos Princípios** — Introdução; Apêndice M

- **Mapa Mental** — Apêndice B
- **MCP** — capítulo conceitual sobre MCP; Matriz de Cobertura de Integrações
- **Matriz de Cobertura de Integrações** — método derivado dos Princípios 4 e 6
- **Memória ♦** — capítulo sobre Memória
- **MTTR** — capítulo sobre LLMOps

O

- **Open source (modelos)** — capítulo sobre Open source; trade-offs canônicos
- **OpenTelemetry GenAI** — capítulo sobre LLMOps
- **Operador ★** — Princípio 9; capítulo sobre Roadmap pessoal; Método de Decisão para Adotar IA
- **Over-refusal** — capítulo sobre Alinhamento

P

- **Plausibilidade ★** — Princípio 1; capítulo sobre Como modelos funcionam; Manifesto dos Princípios
- **Pólice.io (caso)** — capítulo sobre LLMOps
- **Postmortem sem culpa** — capítulo sobre Governança
- **Prompt** — capítulo sobre Engenharia de prompt; Apêndice L; Engenharia de Prompt Estendida
- **Engenharia de Prompt Estendida** — método derivado dos Princípios 2 e 3
- **Prompt injection** — capítulo sobre LLMOps

Q

- **Q/K/V (Query Key Value)** — capítulo sobre Como modelos funcionam

R

- **RACI** — capítulo sobre Governança
- **RAG ♦** — capítulo sobre RAG; trade-offs canônicos
- **Refusal training** — capítulo sobre Alinhamento
- **Responsabilidade Indelegável ★** — Princípio 8; capítulo sobre Governança; Governança Indelegável

- **Reward hacking** — capítulo sobre Alinhamento
- **RLAIF** — capítulo sobre Alinhamento
- **RLHF** — capítulo sobre Alinhamento
- **Roadmap pessoal** — capítulo sobre Roadmap; Apêndice C
- **Rollback** — capítulo sobre LLMOps
- **Rota Dupla de Adoção** — método derivado do Princípio 3

S

- **Sandbagging** — capítulo sobre Alinhamento
- **Severidades de incidente** — capítulos sobre LLMOps e Governança
- **SFT (Supervised Fine-Tuning)** — capítulo sobre Alinhamento
- **Shadow mode** — capítulo sobre LLMOps
- **Span × Trace × Session** — capítulo sobre LLMOps
- **Sparse Autoencoders** — capítulo sobre Alinhamento
- **Sycophancy** — capítulos sobre Alinhamento e Evals

T

- **Termômetro ★** — Princípio 7; capítulo sobre Evals; Pirâmide da Avaliação
- **Tokens ♦** — capítulo sobre Tokens
- **Tokenizer ♦** — capítulo sobre Tokens
- **Trade-offs canônicos** — capítulo sobre Trade-offs
- **Tracing** — capítulo sobre LLMOps
- **Transformer ♦** — capítulo sobre Como modelos funcionam

V

- **Autoavaliação ★** — em cada capítulo; Apêndice A
- **Versionamento** — capítulo sobre LLMOps
- **Vianna Castro Almeida (caso)** — Engenharia de Prompt Estendida
- **Vibe-eval** — capítulo sobre Evals, como anti-padrão

W

- **Workflow determinístico** — capítulo sobre Trade-offs

Apêndice J — Trilha do Número

Atualizado em: junho de 2026 **Política editorial:** instrumento vivo, com revisões publicadas no repositório acompanhante sempre que movimento relevante do mercado, da regulação ou da segurança justifique atualização, sem cadência fixa anunciada

Por que este apêndice existe

A obra inteira opera sob o Princípio Três, a Camada Dupla, que diz que conhecimento em IA vive em dois andares, o padrão que dura e o número que muda. O Framework Nove, Rota Dupla, formaliza essa decisão epistemológica afirmando que a memória profissional deve carregar o padrão, e que o número deve ser consultado, com data e fonte, a cada decisão. Este apêndice é a casa do número. Sem ele, a Rota Dupla seria tese sem prática, e o leitor ficaria sem fonte interna confiável para checar versão de modelo, preço de inferência, posição em benchmark, paper relevante do mês, mudança regulatória em andamento.

Nada aqui pretende durar. Cada item tem data de captura, fonte primária quando existe, e marcador de incerteza quando a confirmação não foi possível. O leitor que tiver dúvida deve sempre conferir na fonte oficial, e quem identificar erro deve enviar correção pelo canal indicado ao final do apêndice.

Estrutura: cinco seções, todas datadas no momento da revisão.

1. Modelos de fronteira e seus preços de inferência.
2. Benchmarks recentes e quem lidera.

- 3. Papers que estão movendo o campo.
- 4. Estado da regulação no Brasil e no mundo.
- 5. Incidentes públicos notáveis que entram no radar do CTO brasileiro.

1. Modelos de fronteira em junho de 2026

A tabela abaixo cobre os oito provedores que dominam a pauta de decisão executiva no Brasil em junho de 2026. Preços de input e output em dólares por milhão de tokens. Janela de contexto em tokens. Data de release ou última atualização significativa. Todos os valores foram verificados contra a fonte primária na data de captura indicada; entradas com revisão programada para a próxima atualização vêm com nota explícita de provisoriedade no corpo do parágrafo de contexto, e não como marcador dentro da tabela.

Provedor	Modelo flagship	Modelo de raciocínio	Input USD por 1M tokens	Output USD por 1M tokens	Janela de contexto	Release / atualização
Anthropic	Claude Opus 4.7	Claude Opus 4.7 em modo Adaptive ou Max Effort	5,00	25,00	1 milhão	16/abr/2026
OpenAI	GPT-5.5	o3 (input 2,00, output 8,00); o4-mini (input 1,10, output 4,40)	5,00	30,00	1 milhão (tier separado para long-context acima de 270 mil)	abr/2026

Provedor	Modelo flagship	Modelo de raciocínio	Input USD por 1M tokens	Output USD por 1M tokens	Janela de contexto	Release / atualizaç
Google DeepMind	Gemini 3.1 Pro	Gemini 3.1 Pro com extended thinking	2,00 abaixo de 200 mil tokens, 4,00 acima	12,00 abaixo de 200 mil tokens, 18,00 acima	2 milhões	19/fev/2026
Meta	Llama 4 Maverick	Llama 4 Behemoth em preview restrito	0,15	0,60	1 milhão	abr/2025, variante experimen Llama-4- Maverick- submetida LMarena mar/2026
DeepSeek	DeepSeek V4 Pro	DeepSeek R1 (input 0,55, output 2,19)	0,435 (cache- miss)	0,87	128 mil	tabela rev em 31/mar 2026
Mistral	Mistral Large 3 (versão 2512)	Magistral, lançado como reasoning em 2025	0,50	1,50	262 mil	01/dez/2025
xAI	Grok 4.3 high	Grok 4.3 em modo think	1,25	2,50 (cache 0,20)	1 milhão, com vídeo nativo	30/abr/2025
Alibaba Qwen	Qwen 3.7 Max	Qwen 3.7 Max com extended thinking	2,50 (cache 0,25)	7,50	1 milhão (saída até 65.536)	20/mar/2025

Notas de contexto importantes para junho de 2026:

Anthropic prepara, em preview restrito, o Claude Mythos, que aparece em vários leaderboards como líder mas não está em produção geral. Trate Mythos como sinal de fronteira próxima, não como opção de adoção.

DeepSeek aplicou novo tarifário em 31 de maio de 2026, encerrando o desconto de setenta e cinco por cento que vigorou durante boa parte de 2025. Os preços listados são pós-desconto. Quem operava com desconto deve recalcular margem antes da próxima fatura.

GPT-5.5 Pro existe em tier “research-grade” com input em 30 dólares por milhão e output em 180 dólares por milhão. Não foi tabulado acima porque sua adoção corporativa é marginal, mas vale citar quando se discutir teto de qualidade para tarefa única e crítica.

A janela de contexto deixou de ser diferencial competitivo entre os três frontiers ocidentais. Gemini lidera em 2 milhões, Claude e GPT-5.5 estabilizaram em 1 milhão. A decisão prática voltou a ser preço por qualidade e custo de output, não capacidade bruta de janela.

2. Benchmarks recentes em junho de 2026

A tabela cobre os sete benchmarks mais citados no debate técnico-executivo de junho de 2026. Score do líder no momento da captura. URL do leaderboard onde o número pode ser conferido em qualquer dia. Quando há divergência metodológica entre fontes, a tabela traz a faixa observada e, no texto seguinte, indica a fonte preferencial para a próxima revisão.

Benchmark	O que mede	Líder atual	Score	Fonte
GPQA Diamond	Raciocínio científico nível PhD em cento e noventa e oito questões mais duras	Gemini 3.1 Pro Preview (Mythos Preview marca 94,6% em leaderboard interno Anthropic, ainda não auditado por terceiros)	94,1%	artificialanalysis.ai/evaluations/gpqa-diamond
SWE-bench Verified	Resolução de issues reais GitHub em projetos Python open source	Claude Mythos Preview em preview; em produção, Claude Opus 4.8	93,9% Mythos, 88,6% Opus 4.8	llm-stats.com/benchmarks/swe-bench-verified
AIME 2025	Olimpíada de matemática com trinta questões de resposta inteira	Kimi K2.5 Reasoning; Gemini 3 Pro reporta cem por cento em variante com ferramentas externas habilitadas	96,1%	benchlm.ai/benchmarks/aime2025
ARC-AGI-2	Raciocínio abstrato e generalização visual	GPT-5.5	85%	arcprize.org/leaderboard

Benchmark	O que mede	Líder atual	Score	Fonte
Humanity's Last Exam	Aproximadamente dois mil e quinhentas questões PhD multi-domínio com cap intencionalmente baixo	Claude Opus 4.8 Adaptive Max Effort em produção; Mythos Preview marca 64,7% em leaderboard interno ainda não auditado	45,7% em produção	artificialanalysis.ai/evaluations/humanitys-last-exam
OSWorld-Verified	Agentes computer-use em sistema operacional real	Holo3-35B-A3B open-weight, Claude Mythos Preview proprietário	82,6% e 79,6%	llm-stats.com/benchmarks/osworld-verified
Video-MME	Compreensão multimodal de vídeo	Gemini 3.1 Pro dominante em múltiplos vídeo-benchmarks; faixa observada entre oitenta e oitenta e cinco por cento conforme fonte	80%-85%	video-mme.github.io

Lições estruturais para junho de 2026:

Benchmarks de raciocínio convergiram para cima nos modelos de fronteira, com vantagens marginais que mudam todo mês. Para decisão corporativa, o ranking absoluto importa menos que o perfil por eixo, conforme tratado no Framework Dois. Em junho de 2026, o

eixo onde a diferença ainda compensa esforço é código complexo, onde Claude mantém vantagem operacional, e raciocínio matemático puro, onde Gemini e Kimi disputam.

Computer-use em SO real virou benchmark relevante. Quem opera agentes que precisam interagir com aplicativos sem API estável deve acompanhar OSWorld-Verified e variantes. Em 2025, esse eixo era exótico, em 2026 é decisão de arquitetura.

3. Papers que estão movendo o campo em 2025-2026

A tabela cobre oito trabalhos que mudaram, ou continuam mudando, a conversa técnica e executiva entre o início de 2025 e o presente. Lista deliberadamente curta, com critério de impacto operacional, não comprehensiveness acadêmica.

Título	Autores / instituição	Mês e ano	Por que importa	URL
DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning	DeepSeek-AI	janeiro de 2025, publicado em Nature em 2025	Prova que RL puro sem chain of thought humano gera raciocínio emergente, virando o blueprint dos reasoning models que dominaram 2025 e 2026	arxiv.org/abs/2501.12948

Título	Autores / instituição	Mês e ano	Por que importa	URL
On the Biology of a Large Language Model + Circuit Tracing	Anthropic Interpretability Team	março de 2025, ferramenta open-source em maio de 2025	Mapeia attribution graphs em Claude 3.5 Haiku e oferece a primeira evidência empírica de planejamento multi-step e features anti-jailbreak em modelo de produção	transformer-circuits.pub/2025/attribution-graphs/biology.html
Are DeepSeek R1 And Other Reasoning Models More Faithful?	Chua et al. (Truthful AI / colaboração acadêmica)	janeiro de 2025	Testa se o chain of thought exposto reflete o cálculo interno real, peça-chave do debate sobre faithfulness em reasoning models	arxiv.org/abs/2501.08156
Large Language Lobotomy: Jailbreaking Mixture-of-Experts via Expert Silencing	te Lintelo, Wu e Picek (TU Delft / Radboud)	fevereiro de 2026	Descreve classe de ataque training-free que desliga experts de segurança em modelos MoE, elevando taxa de jailbreak bem-sucedido de aproximadamente sete para mais de setenta por cento ao silenciar menos de vinte por cento dos experts por camada	arxiv.org/abs/2602.08741

Título	Autores / instituição	Mês e ano	Por que importa	URL
RASA: Routing-Aware Safety Alignment for Mixture-of-Experts Models	Liang et al. (Stony Brook)	fevereiro de 2026, revisado em abril de 2026	Resposta defensiva à classe de ataques anterior, com fine-tune seletivo de experts de safety preservando capacidade em MMLU, GSM8K e TruthfulQA; código público disponível	arxiv.org/abs/2602.04448
Stealing User Prompts from Mixture of Experts (MoE Tiebreak Leakage)	Hayes et al. (Google DeepMind)	outubro de 2024, citado em 2026	Primeiro ataque que extrai prompts de outros usuários via roteamento MoE, risco direto para SaaS multi-tenant	arxiv.org/abs/2410.22884
Towards a Mechanistic Understanding of Large Reasoning Models: A Survey of Training, Inference, and Failures	colaboração acadêmica multi-instituição	janeiro de 2026	Survey-padrão para entender treino, inferência e modos de falha de modelos de raciocínio, referência defensiva obrigatória, organizando achados recentes em três dimensões — dinâmica de treino, mecanismos de raciocínio e comportamentos não intencionais	arxiv.org/abs/2601.19928

Título	Autores / instituição	Mês e ano	Por que importa	URL
DeepSeek-R1 Thoughtology: Let's think about LLM Reasoning	Marjanović et al. (colaboração acadêmica)	abril de 2025	Análise sistemática dos thoughts do R1, referência para auditoria de cadeias de raciocínio em pipelines reais	arxiv.org/abs/2504.07128

Padrão observável em 2025-2026:

A agenda científica deslocou-se de “como fazer o modelo gerar texto melhor” para três frentes simultâneas. Reasoning sob RL puro, interpretabilidade mecanicista das features internas, e segurança em arquiteturas MoE onde o roteamento abre vetores novos de ataque. CTO atento acompanha pelo menos um paper de cada frente por trimestre.

4. Estado da regulação em junho de 2026

EU AI Act

Entrou em vigor em 1 de agosto de 2024, com aplicação geral marcada para 2 de agosto de 2026. Práticas proibidas e AI literacy já se aplicam desde 2 de fevereiro de 2025. Governança e obrigações para modelos de propósito geral entraram em vigor em 2 de agosto de 2025.

Em 2 de agosto de 2026, o bulk das obrigações entra em vigor, incluindo transparência conforme Artigo 50, conformity assessments, gestão de risco, supervisão humana. Quem opera no mercado europeu precisa ter caderno de governança pronto antes dessa data.

Em 7 de maio de 2026, o acordo provisional sobre o Digital Omnibus on AI adiou as obrigações para sistemas High-Risk (HRAIS) de 2 de agosto de 2026 para 2 de dezembro de 2027, uma janela adicional de dezesseis meses. Anexo Um HRAIS adiado para 2 de agosto de 2028.

Guidelines do Artigo 50 estão em consulta pública até 3 de junho de 2026.

PL 2338/2023 no Brasil

Aprovado por unanimidade no Senado em 10 de dezembro de 2024. Em tramitação na Câmara dos Deputados desde março de 2025, em Comissão Especial. Votação foi adiada para 2026 por impasses políticos. Em junho de 2026 está agendado, com data ainda em definição — o leitor deve consultar o portal da Câmara antes de qualquer decisão executiva baseada em prazo, porque calendário legislativo brasileiro tem volatilidade alta e este apêndice é revisado periodicamente, sem cadência fixa.

Modelo adotado é europeu, com classificação por risco em três classes (excessivo, alto, baixo-moderado), direitos do titular, criação do Sistema Nacional de Regulação e Governança de IA, multas até cinquenta milhões de reais por infração.

Vício de iniciativa identificado por juristas: atribuições à ANPD são matéria de iniciativa exclusiva do Executivo. Isso pode forçar emenda substitutiva ou veto presidencial parcial, o que adiciona incerteza sobre a forma final.

NIST AI RMF

Versão base permanece o AI RMF 1.0, publicado em janeiro de 2023. Não há “versão 2.0” formal em junho de 2026. O Generative AI Profile NIST AI 600-1, publicado em 2024, adiciona mais de duzentas ações específicas para LLMs.

Em 7 de abril de 2026, NIST publicou concept note para AI RMF Profile on Trustworthy AI in Critical Infrastructure. Em fevereiro de 2026, o Treasury Department publicou Financial Services AI RMF com 230 control objectives para instituições financeiras. Expectativa para o restante de 2026: addenda 1.1 e novos perfis setoriais.

ISO/IEC 42001

Adoção acelerando em 2026. Fortune 500 começou a exigir de fornecedores em RFP. Certificações públicas confirmadas até a data desta revisão: CrowdStrike em janeiro, CM.com em janeiro, BCG entre as primeiras cem globais em janeiro, Perforce em fevereiro, SAP em 2025. A estimativa de aproximadamente dezesseis organizações

certificadas publicamente no início de 2026, com número crescendo mês a mês, é compilação editorial deste apêndice a partir de releases públicos das próprias empresas; não existe registro central auditado para esse universo, e revisões futuras substituirão esta estimativa por contagem fechada caso uma fonte agregadora confiável passe a publicá-la.

LGPD e ANPD no Brasil

Nota Técnica número 1 de 2026, da ANPD, analisa o Grok integrado ao X e firma posição de que saída de IA referente a pessoa identificável é dado pessoal. Marco importante para qualquer sistema que opere com inferência sobre brasileiros.

Resolução número 23 de 2024 publicou a Agenda Regulatória 2025-2026, com IA como eixo prioritário ao lado de direitos do titular, RIPD, segurança e anonimização.

Quatro eixos de fiscalização para 2026-2027: direitos do titular, dados de crianças e adolescentes, tratamento pelo Poder Público, IA e tecnologias emergentes.

Sandbox regulatório de IA em fase de testes sob supervisão direta da ANPD até dezembro de 2026. Empresas interessadas em testar produto sensível com cobertura regulatória parcial devem submeter aplicação.

ANPD designada como autoridade reguladora residual no PL 2338. Em setores sem regulação específica, ANPD cria normas, supervisiona e aplica sanções.

5. Incidentes públicos notáveis em 2025-2026

A tabela cobre sete incidentes que entraram no radar regulatório, jurídico ou de segurança no período. Critério de inclusão: incidente público com aprendizado executivo para CTO brasileiro.

Incidente	Data	O que aconteceu	Por que importa ao CTO BR
Baltimore contra xAI, X e SpaceX por imagens sexualizadas geradas por Grok	dezembro de 2025 a janeiro de 2026	Processo municipal apurou que Grok gerou entre 1,8 e 3 milhões de imagens sexualizadas, com aproximadamente vinte e três mil retratando menores	Risco de responsabilidade civil e criminal para deploy de modelos generativos de imagem sem guardrails. Chamou atenção da ANPD via Nota Técnica 1 de 2026
EchoLeak, CVE-2025-32711	divulgado em junho de 2025	Primeira vulnerabilidade zero-click de prompt injection documentada publicamente para exfiltração em LLM em produção, no Microsoft 365 Copilot	Define nova classe de CVE. IA conectada a e-mail ou SharePoint é vetor de exfiltração sem clique do usuário. Obrigatório no threat model
Vercel e Context.ai OAuth breach	abril de 2026	Funcionário concedeu OAuth com escopo "Allow All" a ferramenta de IA. Comprometimento do Context.ai escalou para lateral movement na Vercel	Confirma OAuth de produtividade IA como porta de entrada. Exige revisão de scopes e least-privilege em qualquer integração SaaS mais IA

Incidente	Data	O que aconteceu	Por que importa ao CTO BR
Eightfold AI class action sob FCRA	janeiro de 2026	Class action argumentou que plataforma de hiring com IA operava como consumer reporting agency não-registrada, sem disclosure, consent ou dispute	Precedente direto para uso de IA em RH no Brasil sob LGPD e futuro PL 2338, como sistema de alto risco
Cisco multi-turn jailbreak em modelos open-weight	2026	Teste com oito modelos open-weight mostrou que ataques multi-turn tiveram aproximadamente noventa e três por cento de sucesso	Quem deploia open-weight on-prem precisa de camada externa de guarda. Modelo “alinhado” não basta
Mercor data breach	1 de abril de 2026	Recruiting platform de IA enfrentou ao menos quatro class actions no Northern District of California por vazamento de dados	Reforça que dados de candidato em pipeline de IA são jurisdição LGPD e ANPD se houver brasileiros entre os afetados
Chinese state-actor automatizando ataque com AI coding assistant	2025 a 2026	Grupo estatal chinês jailbroke assistente de código e automatizou entre oitenta e noventa por cento da cadeia de ataque com IA agêntica	Marco: IA agente como arma ofensiva real, não teórica. Eleva a régua de SOC e SBOM

Estatística contextual: AI Incident Database registrou 346 casos em 2025, dos quais 179 foram de mídia sintética e 37 de conteúdo violento ou inseguro.

Como contribuir com correções

Esta trilha evolui no repositório acompanhante público sempre que movimento relevante do mercado, da regulação ou da segurança justifique atualização. Para receber notificação de novas revisões, ative *watch* no repositório no GitHub. Correções, atualizações ou novas entradas podem ser enviadas como issue ou pull request com fonte primária; contribuições qualificadas são incorporadas nas revisões seguintes, com atribuição quando o contribuidor autoriza.

Toda alteração registra três campos no log de revisão: data da mudança, item alterado, fonte que motivou a alteração. O log integra o material publicado a cada revisão, para que o leitor possa, em qualquer momento, reconstituir o que a obra afirmou em cada janela de tempo.

Política editorial

O autor não promete cadência fixa de release. O instrumento é vivo, e o ato de manter o número auditável e datado depende de janela de pesquisa que nem sempre se encerra no mês do calendário. A política assumida é simples e dura: publicar quando a revisão estiver pronta para ser cumprida sob crítica pública, jamais antes; sinalizar com clareza no cabeçalho a data da última revisão; e abrir revisões emergenciais a qualquer momento quando movimento relevante do mercado, da regulação ou da segurança justifique correção imediata.

Honestidade temporal é parte da promessa da Rota Dupla, e essa honestidade fica mais bem servida pela ausência de calendário fixo do que pelo descumprimento de um calendário que prometido demais.

Editor desta trilha

Editor responsável: Fabio Garcia, autor da obra.

O editor mantém o registro datado de cada revisão e responde pelas escolhas de inclusão, exclusão, classificação de impacto e nível de incerteza atribuído a cada item. Discordâncias técnicas, sugestões de inclusão e identificação de erro devem ser dirigidas ao repositório acompanhante, com fonte primária; respostas editoriais a contribuições qualificadas são incorporadas nas revisões seguintes e creditadas quando o contribuidor autoriza.

Apêndice J — Trilha do Número. Política editorial: instrumento vivo, sem cadência fixa anunciada. Editor: Fabio Garcia.